

Explorarea Datelor (Exploratory Data Analysis)

1. Analiza tipului de atribute și a plajei de valori a acestora

Pentru datele din PIRvision:

	count	mean	std	min	25%	50%	75%	max	missing_values
Day Index	8000.0	2.001125	5.297724e-01	1.0	2.0	2.0	2.0	3.0	0
Temp (F)	8000.0	80.394750	2.286321e+01	0.0	86.0	86.0	88.0	89.0	0
Temp (C)	8000.0	26.701250	1.242631e+01	-17.0	30.0	30.0	31.0	31.0	0
OBS_1	7202.0	298767.516662	4.631447e+06	2613.0	10335.0	10433.0	10563.0	111602625.0	798
OBS_2	8000.0	10959.839000	1.366988e+03	2092.0	10775.0	11000.0	11281.0	16928.0	0
...
OBS_54	8000.0	10585.347125	4.288494e+02	2603.0	10513.0	10596.0	10684.0	16383.0	0
OBS_55	8000.0	10449.253750	4.179482e+02	2602.0	10388.0	10453.0	10523.0	16383.0	0
OBS_56	8000.0	11013.778000	4.554899e+02	2547.0	10928.0	11026.0	11127.0	17146.0	0
OBS_57	8000.0	10027.365500	4.015679e+02	2624.0	9957.0	10033.0	10108.0	15713.0	0
Class	8000.0	0.332750	8.184505e-01	0.0	0.0	0.0	0.0	3.0	0

61 rows × 9 columns

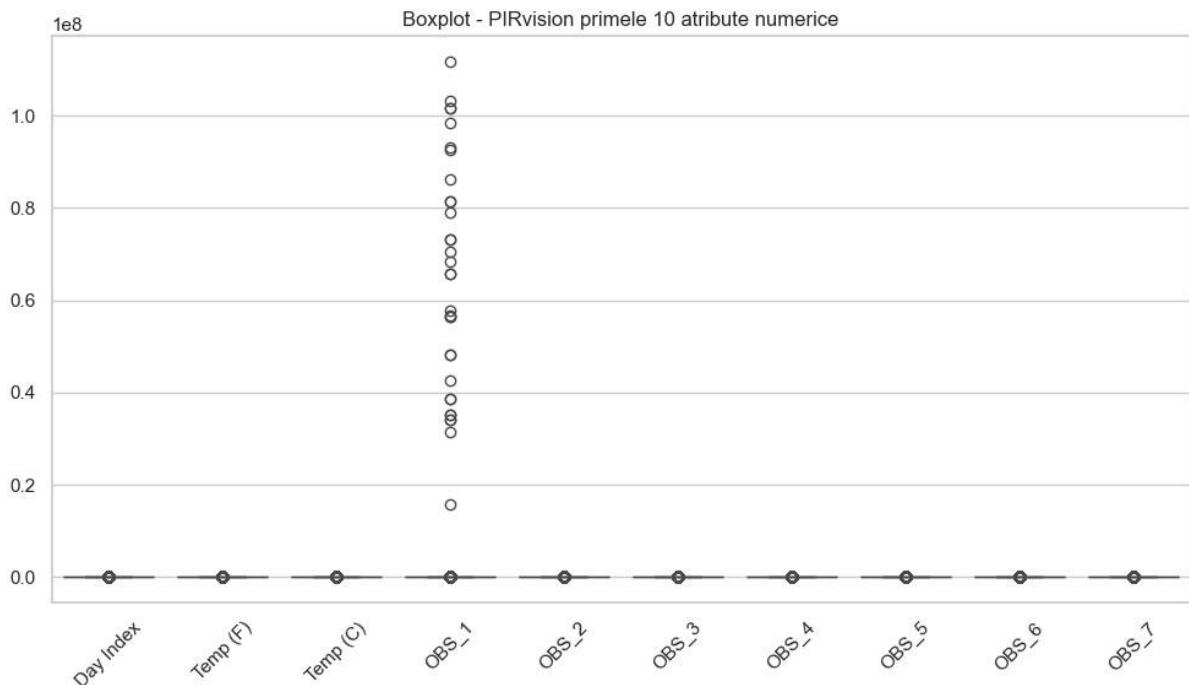
Observ că atributul OBS_1 are valoarea maxima mult mai mare fata de restul atributelor, precum și deviația standard, adică sunt valori extreme. De asemenea, observ că sunt multe valori lipsă (aproximativ 10%). Restul valorilor par normale.

Pentru Temp(F) și Temp(C): mediile par normale, însă temperaturile minime sunt cam scăzute și poate semnifica o posibilă eroare.

Atributul Class este eticheta de clasa, cu valori între 0 și 3.

Atributul "Day Index" are doar 3 valori posibile, fiind atribut ordinal.

Grafic boxplot realizat pentru primele 10 atribute numerice:



Observ ca doar OBS_1 are valori extreme foarte mari fata de restul atributelor care au valori rezonabile.

Pentru datele din Air pollution:

	count	mean	std	min	25%	50%	75%	max	missing_values
Overall AQI	18770.0	71.981726	56.110722	7.000000	39.000000	55.000000	79.000000	500.000000	0
CO AQI Value	18770.0	41.444700	196.121182	0.000000	1.000000	1.000000	2.000000	1001.368367	0
Ozone AQI Value	16900.0	35.372781	28.422401	0.000000	21.000000	31.000000	40.000000	222.000000	1870
NO2 AQI Value	18770.0	3.068727	5.300815	0.000000	0.000000	1.000000	4.000000	91.000000	0
PM2.5 AQI Value	18770.0	68.490996	54.717105	0.000000	35.000000	54.000000	78.000000	500.000000	0
Volatile_Organic_Compounds	18770.0	176.279602	137.198201	-8.563753	92.398163	141.208711	201.670858	1272.469897	0
Sulfur_Dioxide	18770.0	7.503989	10.745942	-20.328019	1.214184	5.572767	10.804549	159.231403	0

-Atributul “CO AQI Value” are o valoare maxima 1001.37 extrem de ridicata fata de restul valorilor, inclusive fata de 75%(2), fiind valoare extrema. La fel si std este foarte mare fata de medie.

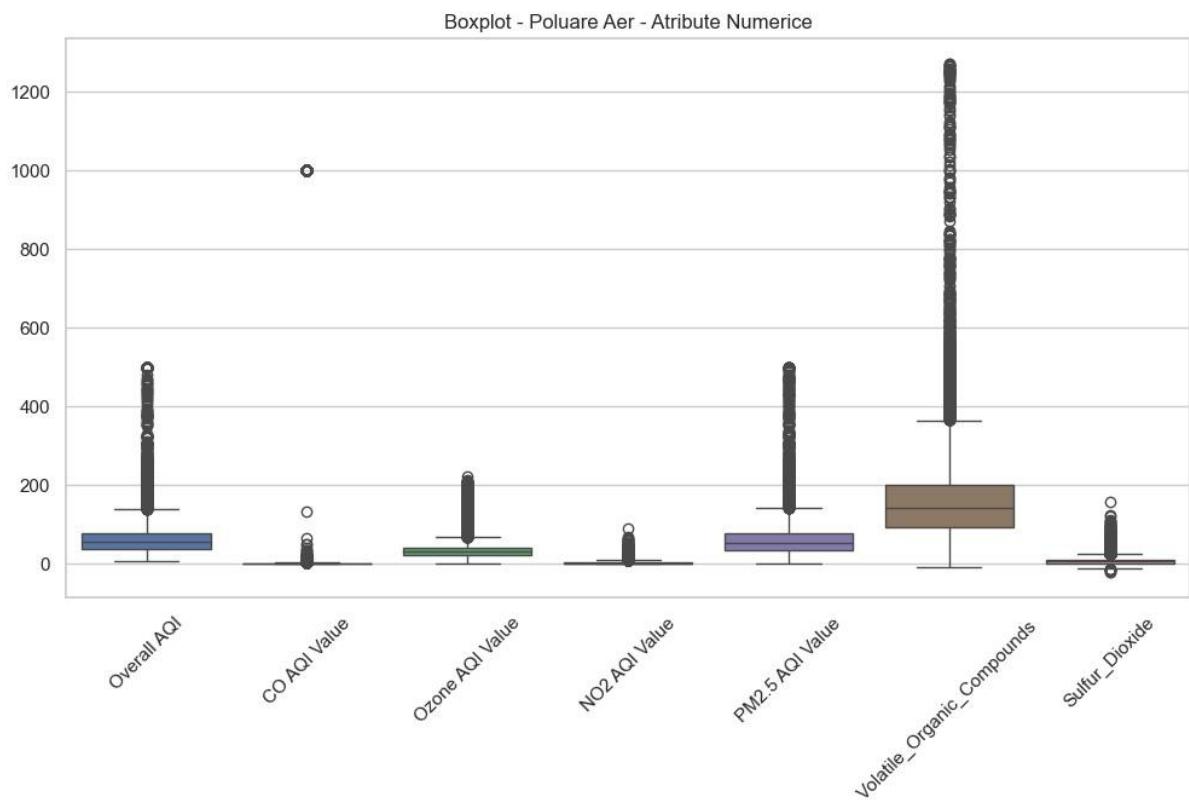
-“Average AQI” pare sa aiba valori normale.

-“NO2 AQI Value” poate avea outlieri pentru ca are distributie asimetrica, avand majoritatea valorilor mici, dar nu reprezinta o problema mare.

-“PM2.5 AQI Value” este atribut bun.

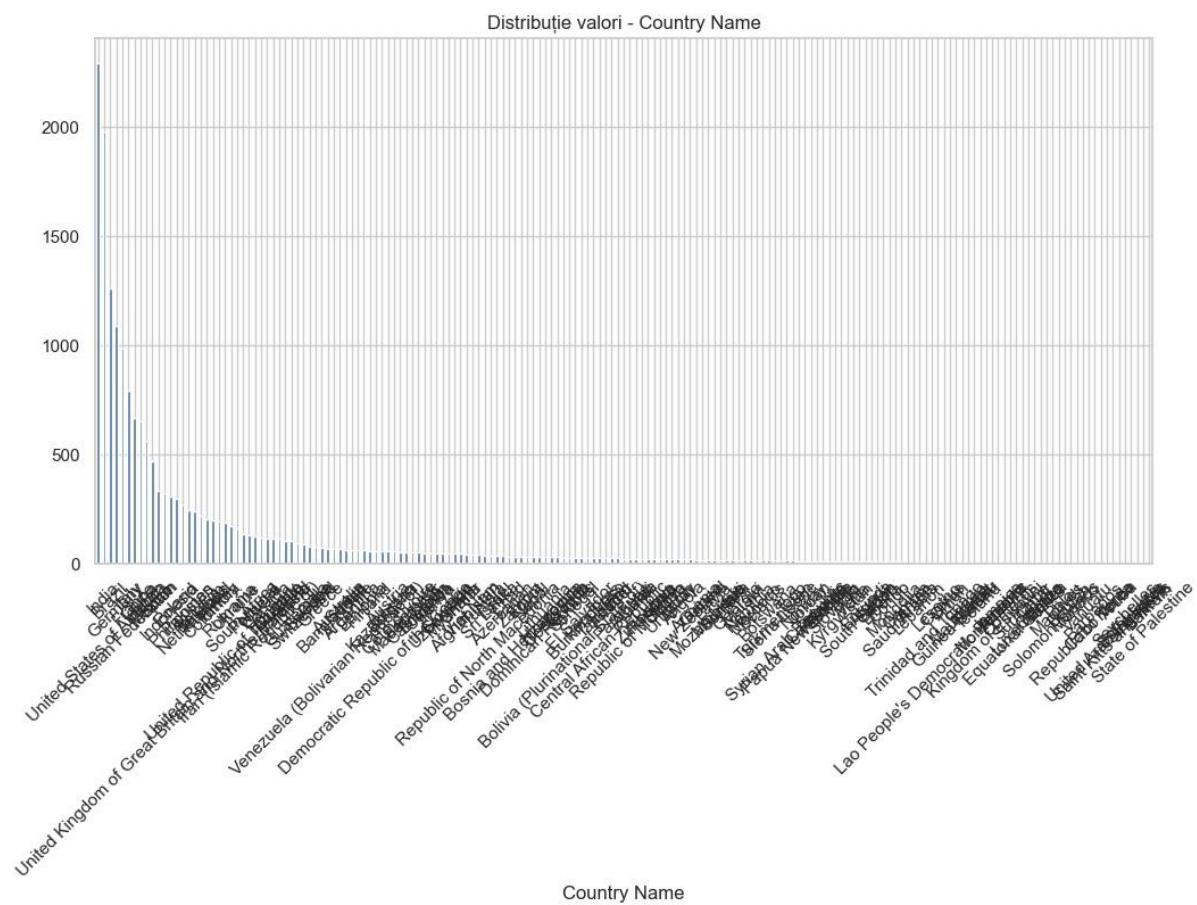
-“Volatile Organic Compounds(VOC)” are minimul mai mic decat 0, cee ace este o eroare de sensor, are valoarea maxima 1272 ceea ce este mult peste 75%(201), adica este outlier. - “Sulfur Dioxide” are valoarea minima negativa, ceea ce este imposibil, adica este eroare de masurare.

Graficul Boxplot:



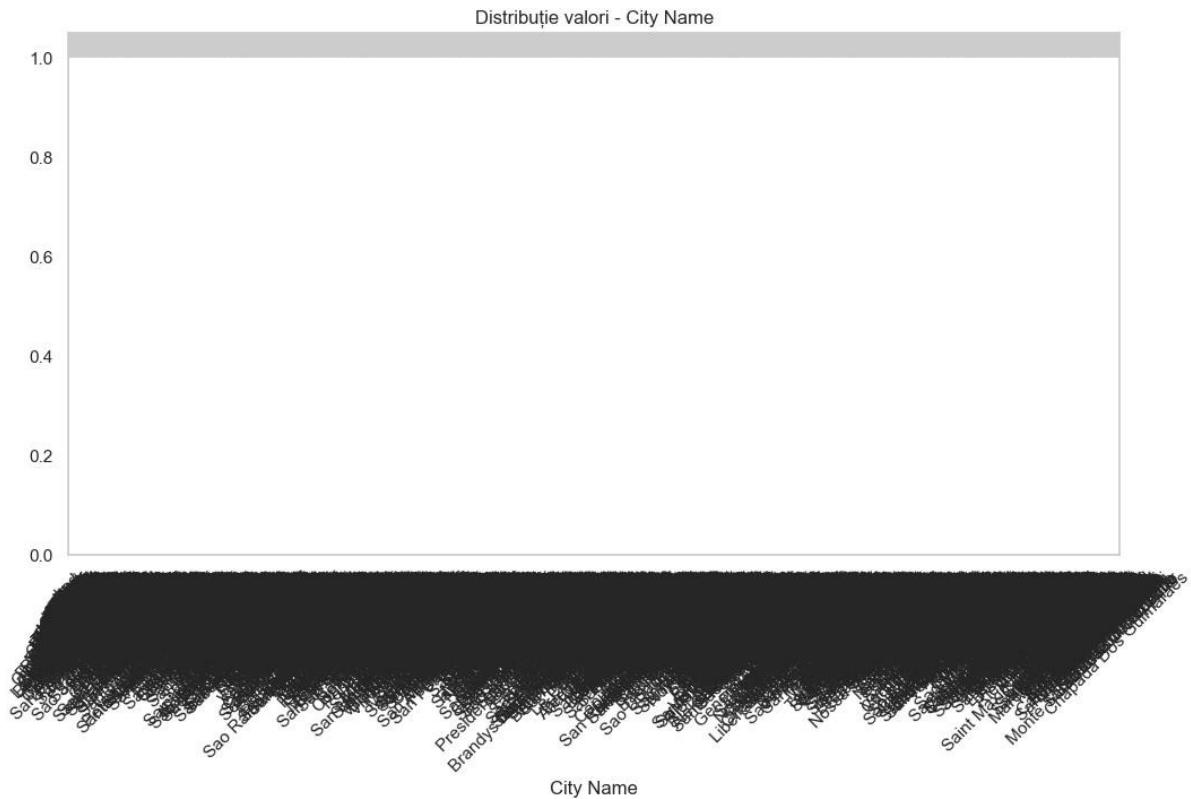
Observ că “CO AQI Value” are valori foarte mari(> 1000), “PM2.5 AQI Value” are multe valori peste 100 și ajung până la 400-500, “Volatile Organic Compounds” are extrem de multe valori peste 1000 și “Sulfur Dioxide” are valori negative imposibile. Restul valorilor sunt bune

Pentru atribute discrete sau ordonale:



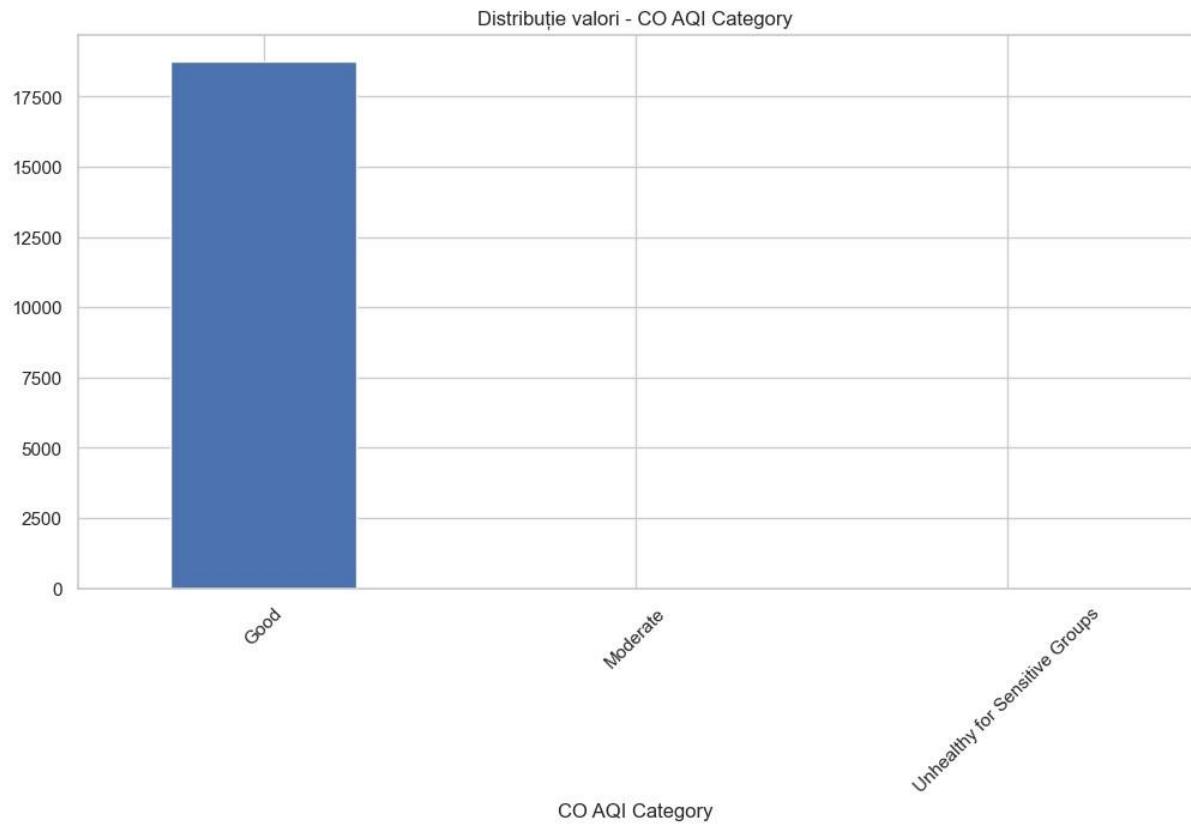
Country Name -> missing: 349, unique: 175

Coloana "Country Name" contine 175 de valori unice, cu o distributie dezechilibrata. Cateva tari dominante au un numar foarte mare de inregistrari(pest 2000), in timp ce majoritatea apar rar.



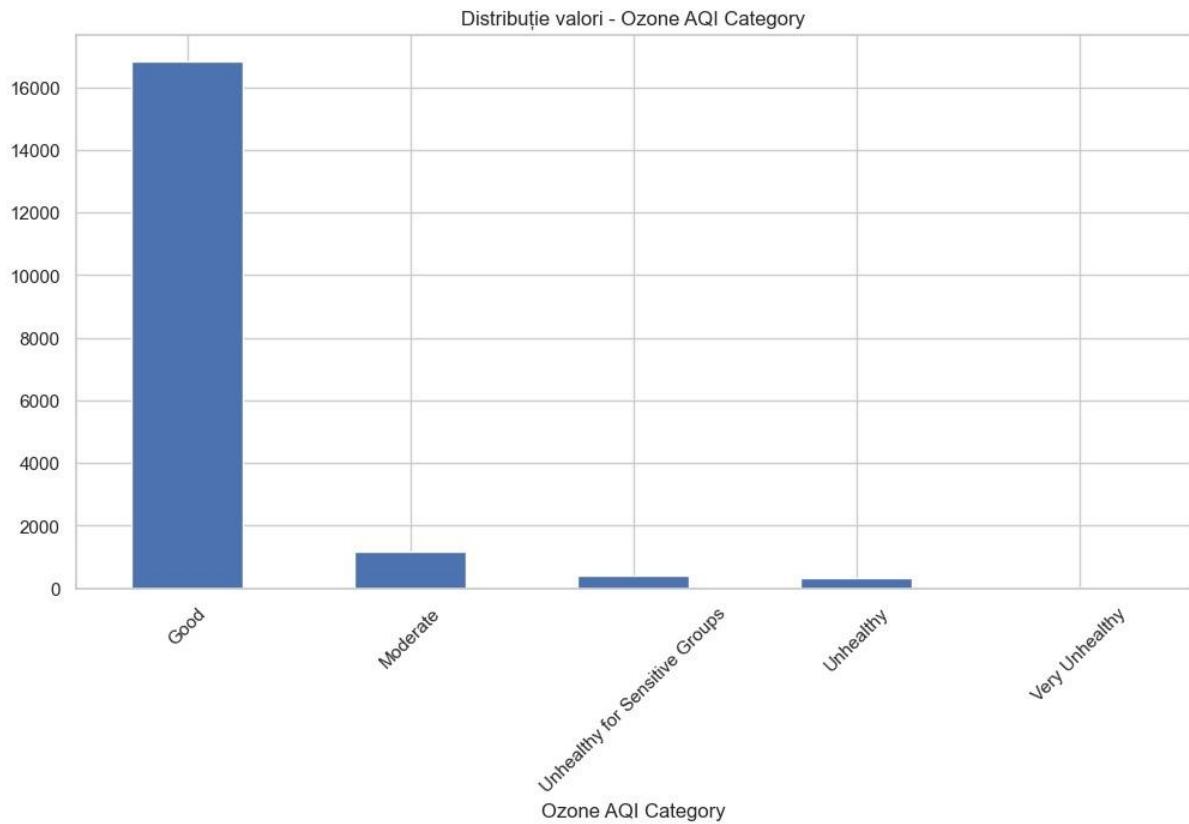
City Name -> missing: 0, unique: 18770

Coloana "Country Name" contine un numar extrem de mare de valori unice, cee ace il face foarte greu de reprezentat visual printr-un grafic de tip barplot.



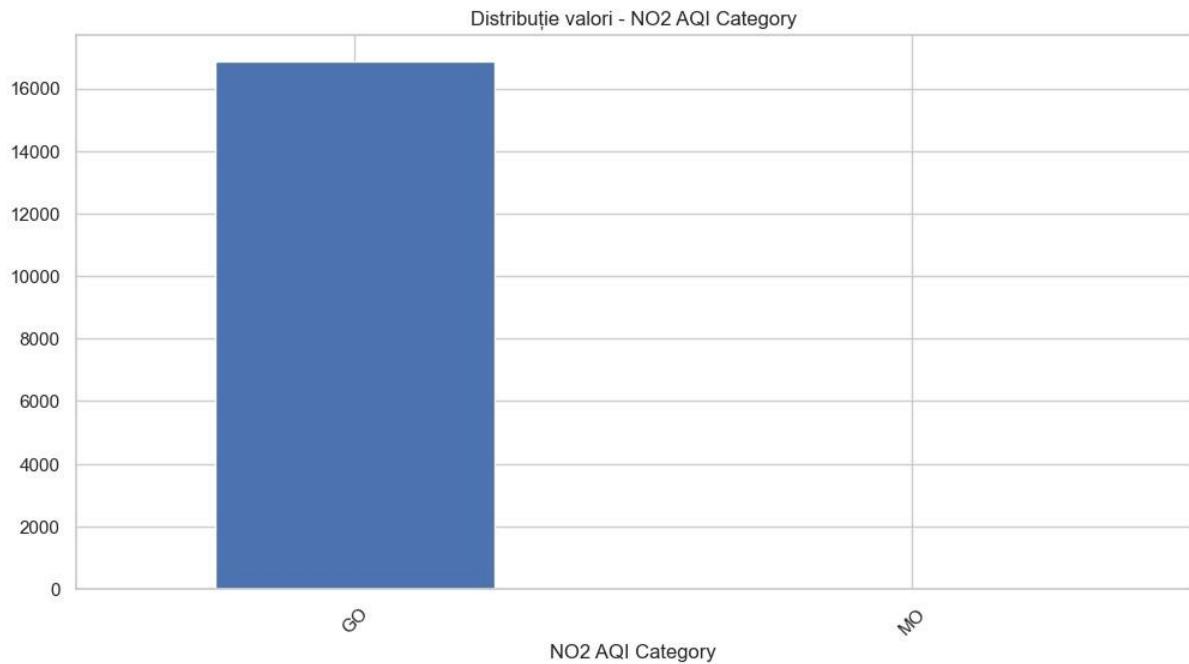
CO AQI Category -> missing: 0, unique: 3

Atributul “CO AQI Category” este puternic dezechilibrat, avand majoritatea valorilor în categoria “Good”, însemnând ca în majoritatea locațiilor monitorizate nivelul de CO este sigur.



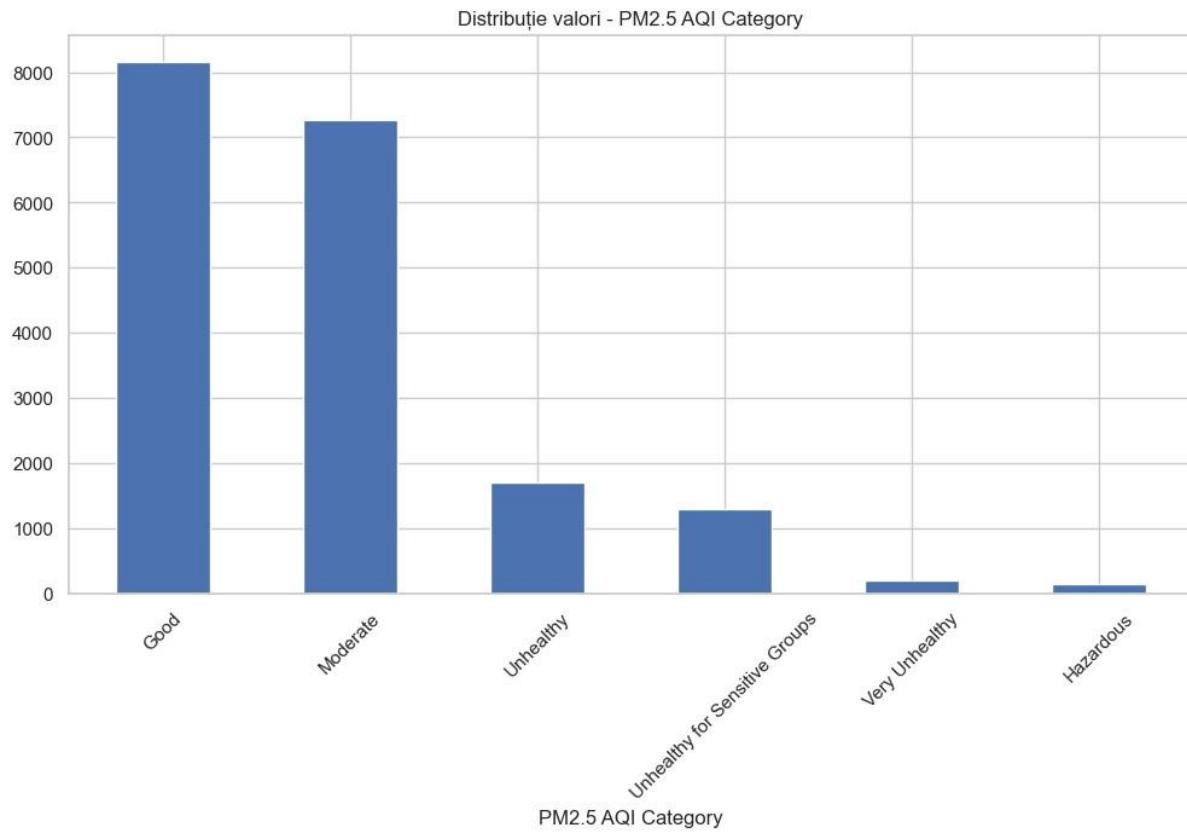
Ozone AQI Category -> missing: 0, unique: 5

Atributul “Ozone AQI Category” este distribuit dezechilibrat, insă mai variat decât cel precedent. “Good” este cea mai frecventă clăsa, dar distribuția include și valori semnificative din categoriile “Moderate”, “Unhealthy for Sensitive Groups” și “Unhealthy”.



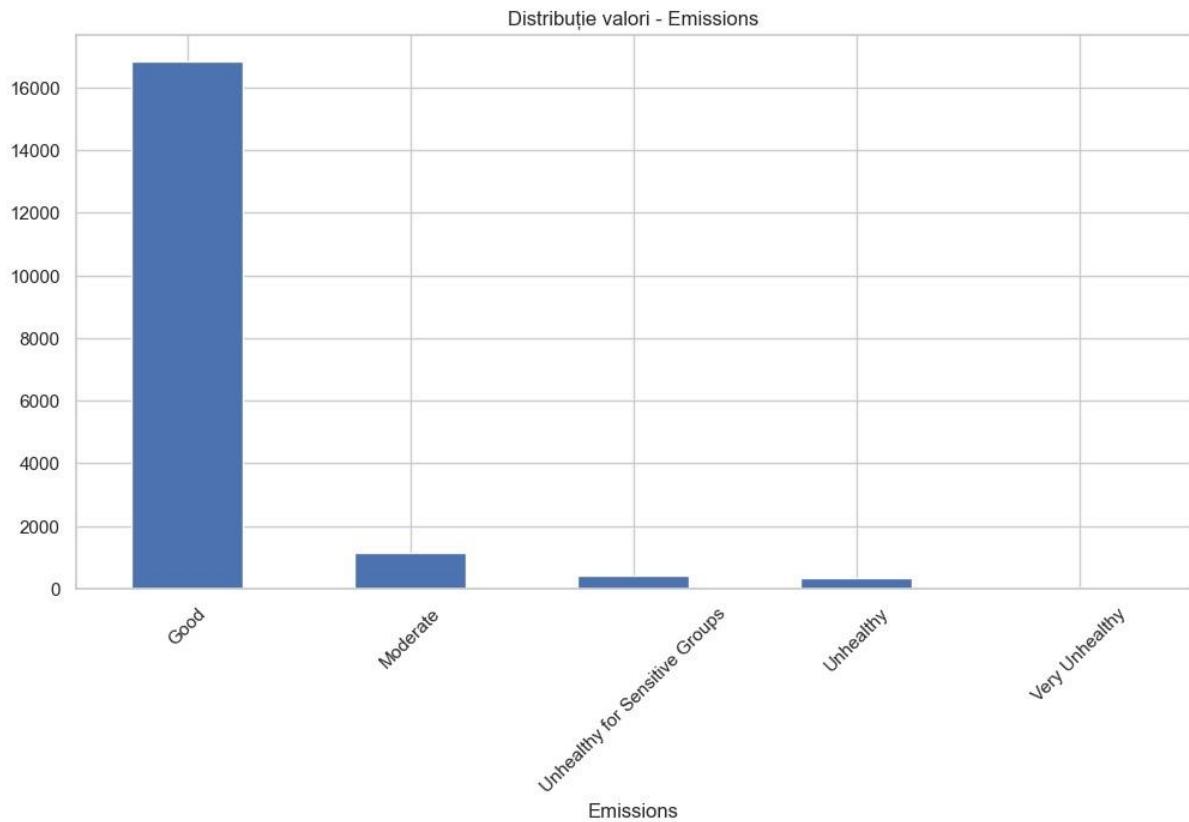
NO2 AQI Category -> missing: 1893, unique: 2

Atributul “NO2 AQI Category” are si el o distributie dezechilibrata, cu majoritatea observatiilor incadrate in clasa “Good”.



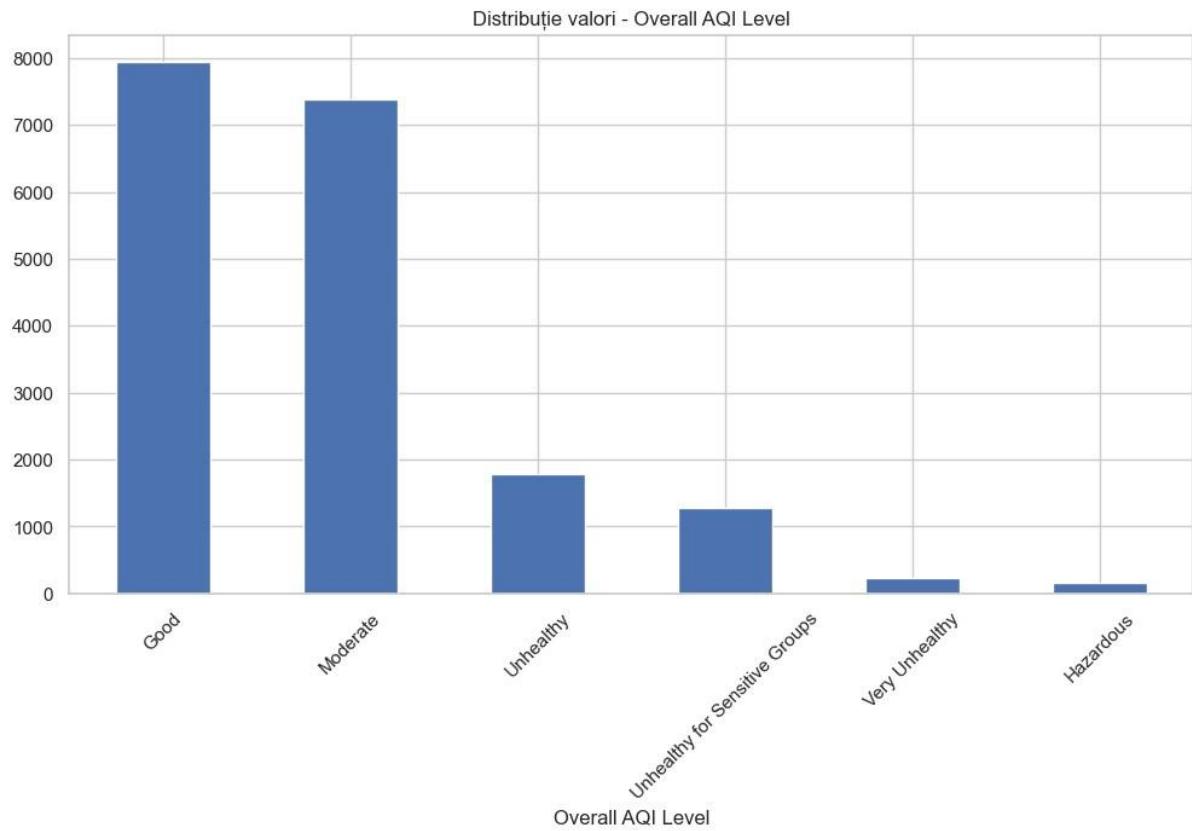
PM2.5 AQI Category -> missing: 0, unique: 6

Atributul “PM2.5 AQI Category” are o mai buna acoperire decat alte categorii. Clasele “Good” si “Moderate” domina distributia, totusi aparitia unor clase semnificative de risc(“Unhealthy”, “Unhealthy for Sensitive Groups”, “Very Unhealthy”, “Hazardous”) ofera o oportunitate buna pentru algoritmii de clasificare sa invete diferențierea intre conditii normale si periculoase.



Emissions -> missing: 0, unique: 5

Atributul “Emissions” are o distribuție puternic dezechilibrata, fiind dominate de categoria “Good”. Categoriile mai severe sunt rare.



Overall AQI Level -> missing: 0, unique: 6

Distributia "Overall AQI Level" are predominante starile de aer "Good" si "Moderate", insa sunt prezente si date despre restul categoriilor.

Tabel cu valori lipsă și unice:

	Atribut	Valori lipsă	Valori unice
0	Country Name	349	175
1	City Name	0	18770
2	CO AQI Category	0	3
3	Ozone AQI Category	0	5
4	NO2 AQI Category	1893	2
5	PM2.5 AQI Category	0	6
6	Emissions	0	5
7	Overall AQI Level	0	6

Atributele "Country Name" și "City name" contin multe valori unice.

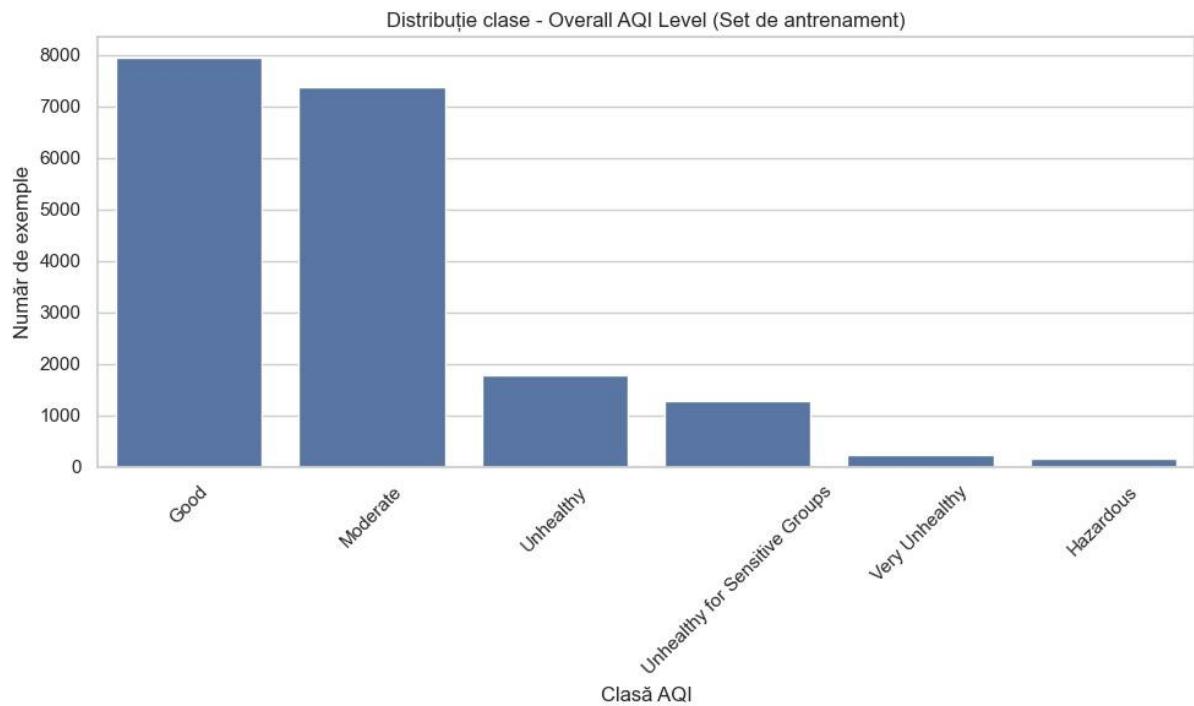
"NO2 AQI Category" are multe valori lipsă.

"Overall AQI Level" este bine definită, dar dezechilibrată.

Restul atributelor sunt bine structurate.

2. Analiza echilibrului de clase Air

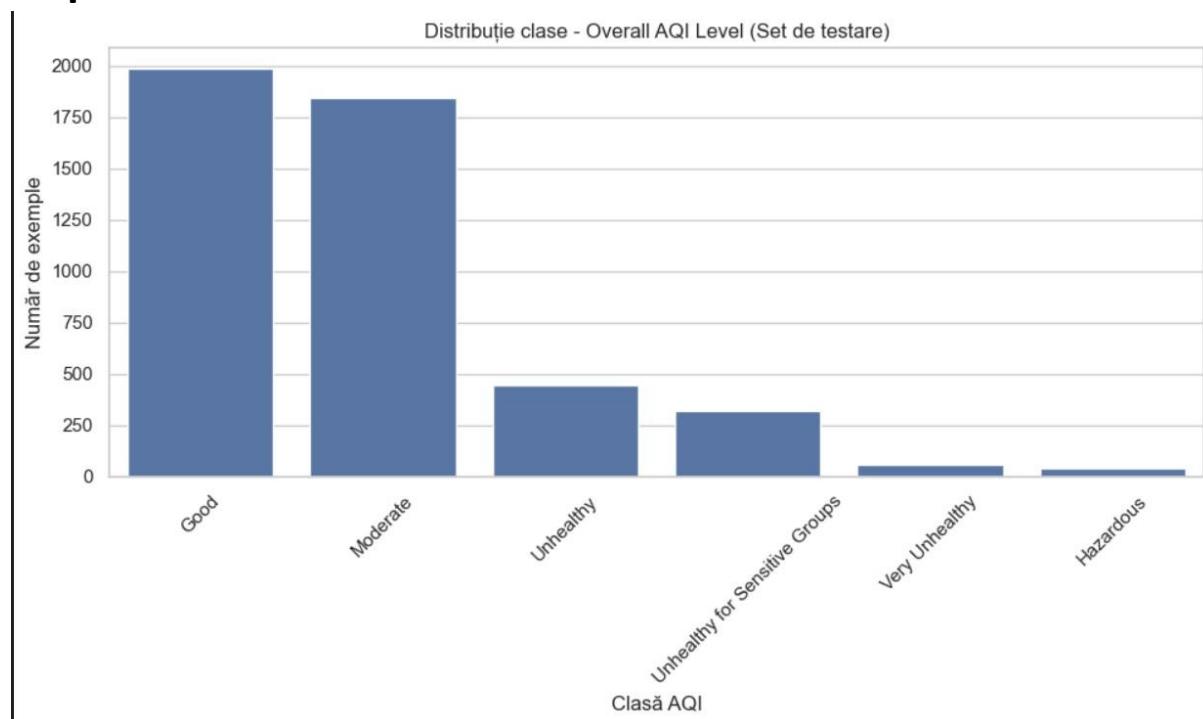
Pollution - train:



- Clasele "Good" și "Moderate" sunt cele mai frecvente, cu cate aproximativ 8000 exemple fiecare
- "Unhealthy", "Unhealthy for Sensitive Groups" au semnificativ mai putine exemple(1000-2000)
- "Very Unhealthy" și "Hazardous" au un numar foarte mic de exemple(sub 500).

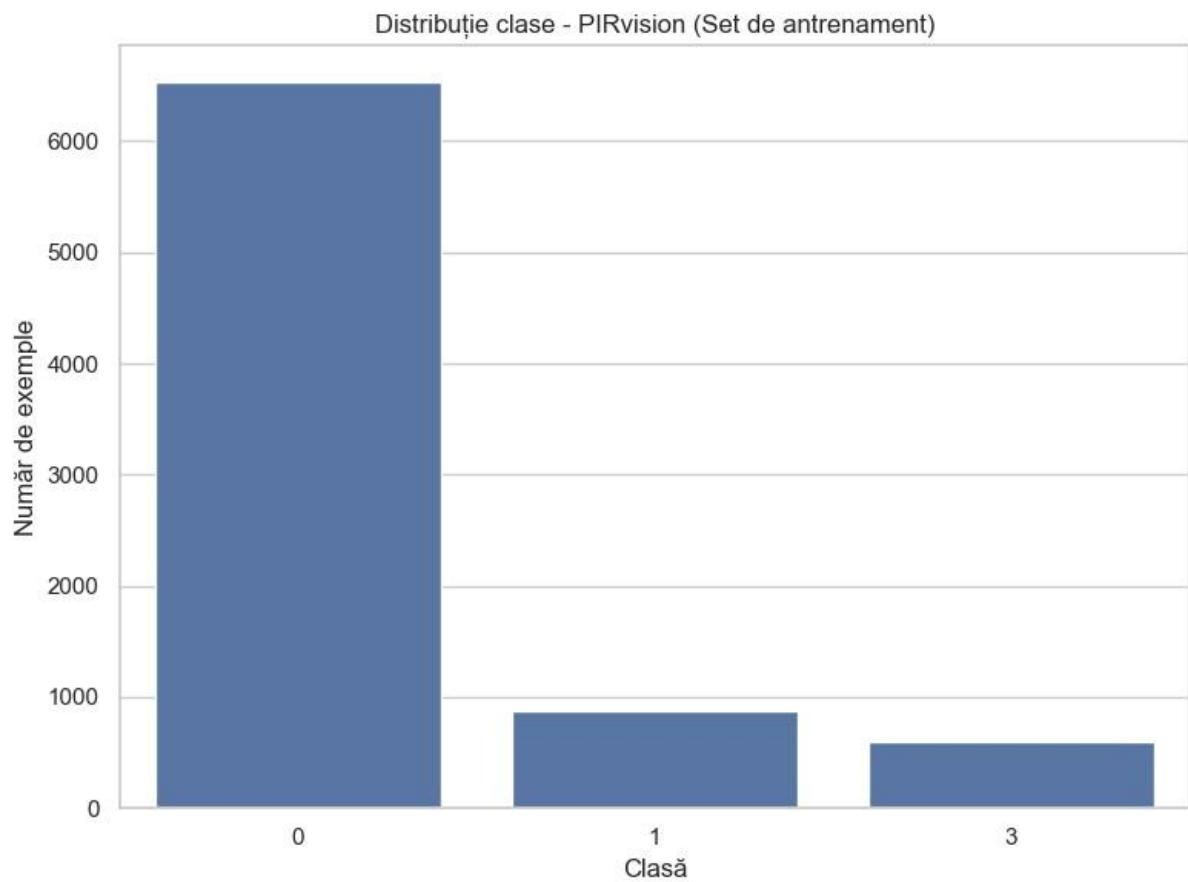
Set de date dezechilibrat

Air pollution – test:



Distributie asemanatoare cu cea din train, insa, fiind un set de date cu raport $\frac{1}{4}$ din cel din train, asa sunt si valorile din grafic.

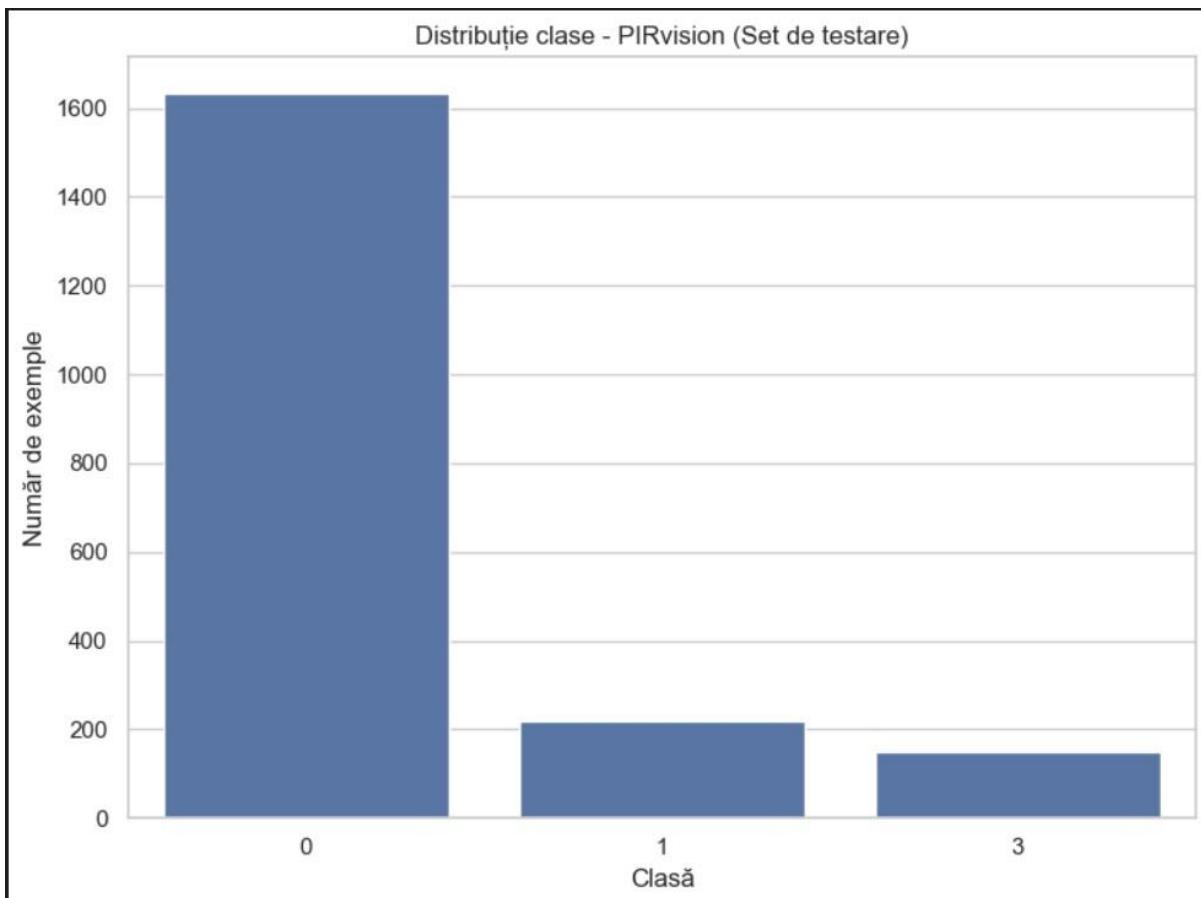
PIRvision – train :



- clasa 0 are peste 6500 exemple, clasa dominantă
- clasa 1 sub 1000 exemple
- clasa 2 sub 700 exemple

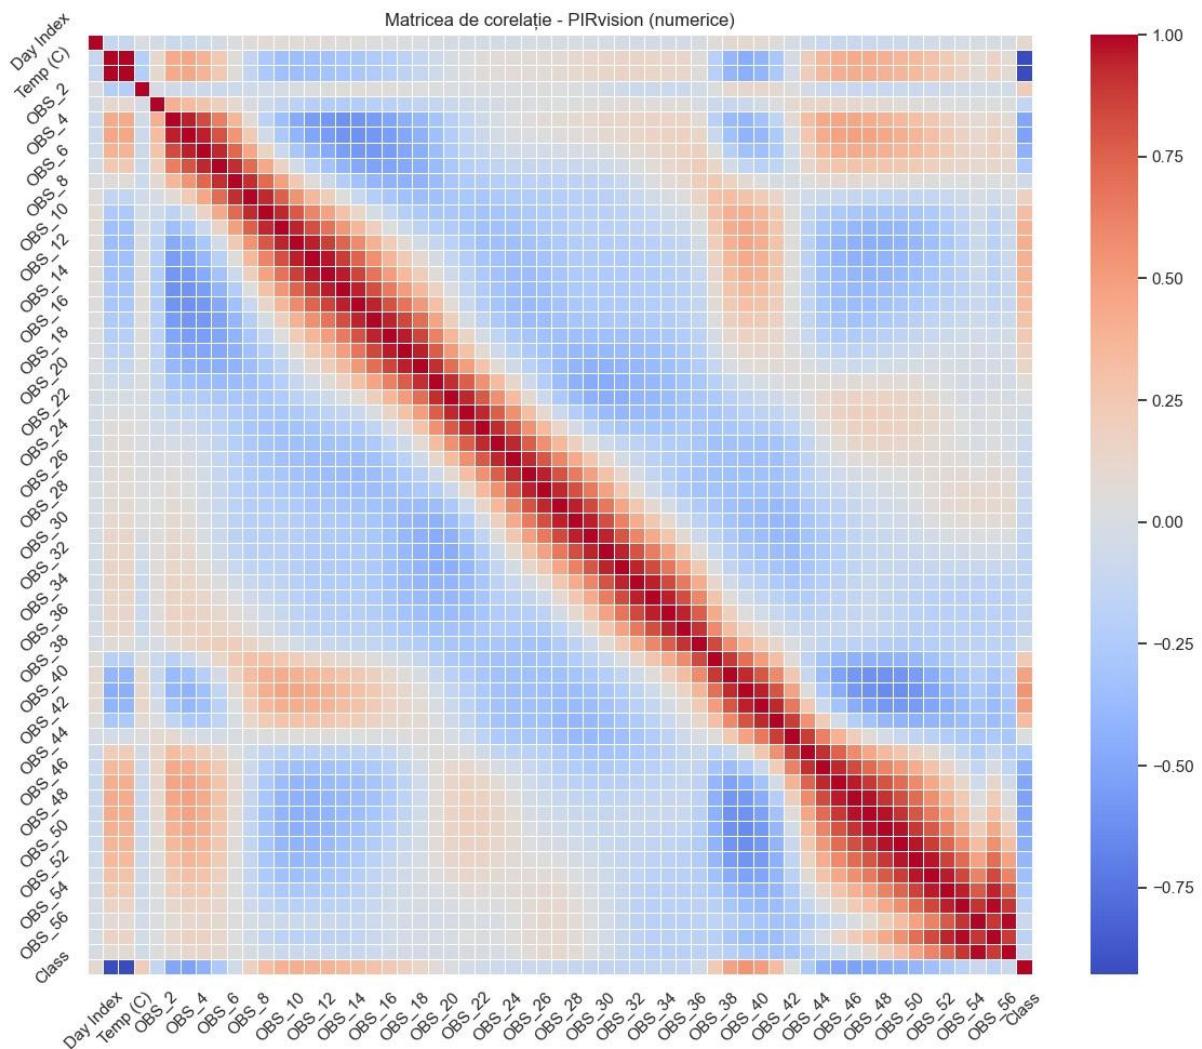
Dezechilibru intre clase. Modelul tinde sa favorizeze clasa 0.

PIRvision – test:



Acelasi lucru ca la Air Pollution. Setul de test are raport $\frac{1}{4}$ din setul de train si asa sunt si valorile fata de cele din train.

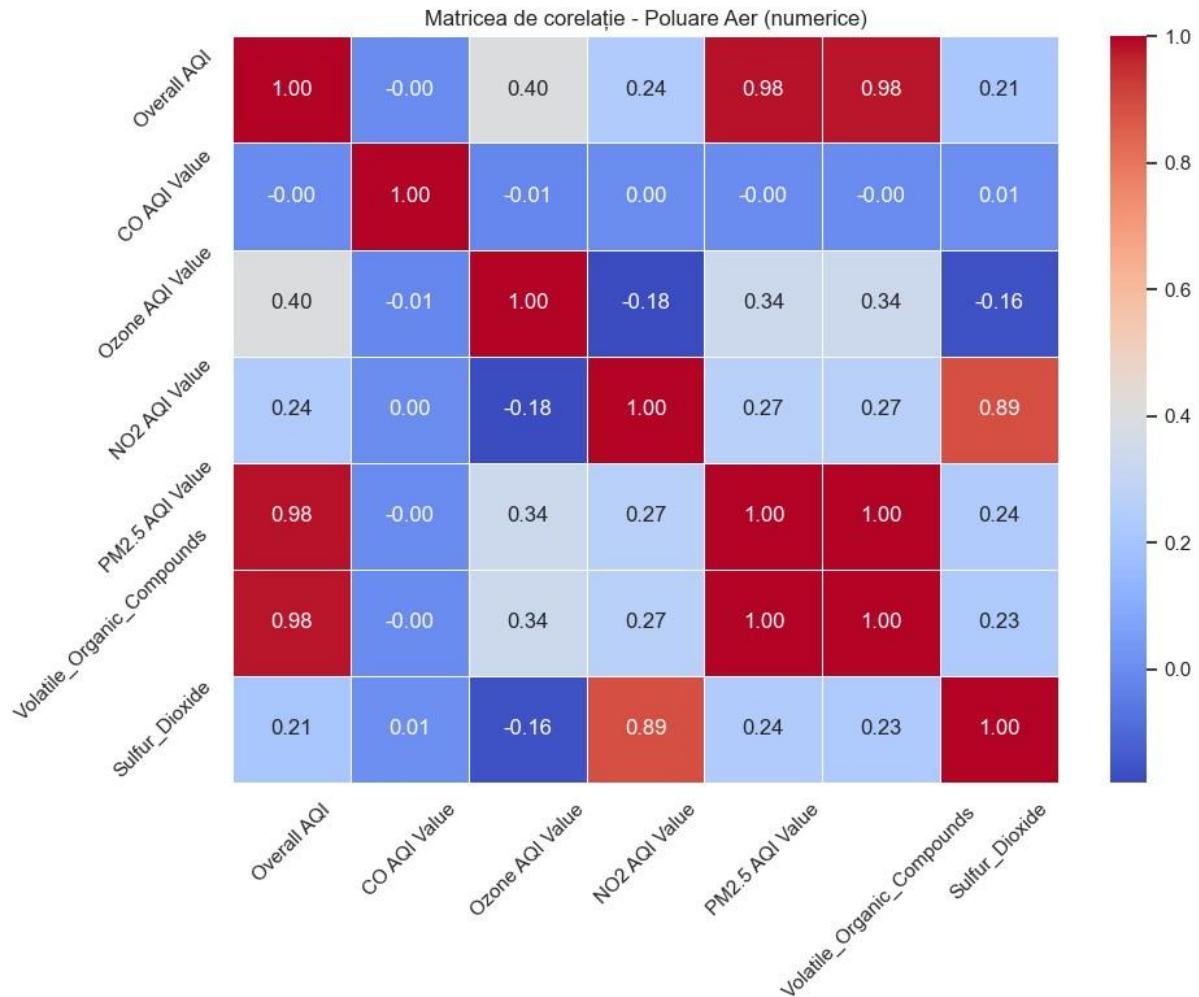
3. Analiza corelației între attribute PIRvision: corelații între attribute numerice



- Observ banda rosie diagonala care confirma ca fiecare atribut este corelat perfect cu el insusi.
- Foarte multe dintre attributele OBS1-57 sunt puternic corelate intre ele, ceea ce este suprapunere informationala si un potential de eliminare a unora dintre ele.
- Temp(C) si Temp(F) sunt perfect corelate negative deoarece exprima aceeasi temperatura in unitati diferite.
- "Day Index" are corelatii slabe cu celelalte, cee ace indica faptul ca nu este redundant.

-“Class” are o corelatie slaba cu majoritatea atributelor

Poluare aer: corelații între attribute numerice



- “Overall AQI”, “PM2.5 AQI Value” si “Volatile Organic Compounds” sunt puternic corelate intre ele(coef. 0.98-1.00). Ele contin informatie suprapusa
- “Sulfur Dioxide” este puternic corelat cu “NO2 AQI Value”(0.89), cee ace sugereaza ca pot reflecta surse commune de poluare sau acelasi tip de activitate industriala.
- Atributele precum “CO AQI Value” sau “Ozone AQI Value” au

corelatii foarte slabe cu celelalte variabile, ceea ce inseamna ca sunt relative independente si pot aduce informatie suplimentara.

Poluare aer: analiză relații între categorice (frecvență combinată)

Preprocesarea datelor

1. Date lipsă pentru un atribut într-un eşantion

```
PIRvision - Valori lipsă:
```

```
Timestamp    788
Day          790
OBS_1        798
dtype: int64
```

```
PIRvision - Valori lipsă în setul de testare:
```

```
Timestamp    212
Day          210
OBS_1        202
dtype: int64
```

```
Air Pollution - Valori lipsă:
```

```
Country Name      349
Ozone AQI Value   1870
NO2 AQI Category  1893
dtype: int64
```

```
Air Pollution - Valori lipsă în setul de testare:
```

```
Country Name      78
City Name          1
Ozone AQI Value   476
NO2 AQI Category  453
dtype: int64
```

Aceastea sunt datele lipsa din ambele seturi de date. Pentru imputare am folosit media aritmetica pentru attributele numerice (“OBS_1” si “Ozone AQI Value), folosind(strategy=“mean”), astfel incat distributia sa fie mentinuta cat mai aproape de cea initiala, iar pentru “NO2 AQI Category” si “Country name” am folosit valoarea cea mai frecventa(strategy=“most_frequent”) presupunand ca aceasta reflecta cel mai probabil contextual lipsa.

2. Valori extreme pentru un atribut într-un eşantion Pentru a identifica valorile extreme, am folosit regula intercuartilica: un punct este considerat outlier daca se afla in afara intervalului $Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR$, unde Q_1 este percentila 25, Q_3 percentila 75, iar $IQR = Q_3 - Q_1$. Valorile extreme au fost apoi marcate ca lipsa (NaN), iar imputarea s-a realizat folosind media aritmetica a fiecarei coloane.

3. Atribute redundante (puternic corelate)

In urma analizei de la pasul 3.1, am identificat atribute numerice puternic corelate intre ele, ceea ce indica redundanta informationala. Astfel, am aplicat o eliminare a atributelor care au un coefficient de corelatie mai mare decat: -0.95 in setul PIRvision(“OBS_48”, “OBS_49”, “OBS_50”) -0.9 in serul Poluare Aer(“PM2.5 AQI Value”, “Volatile_Organic_Compounds”)

4. Plaje valorice de mărimi diferite pentru atributele numerice

Pentru a preveni diferențele de scala sa influenteze negative antrenarea modelelor de clasificare(in general regresia logistica) am aplicat standardizarea atributelor numerice, transformand fiecare coloana numérica astfel incat sa abia media = 0 si std = 1.

Utilizarea algoritmilor de Învățare Automată

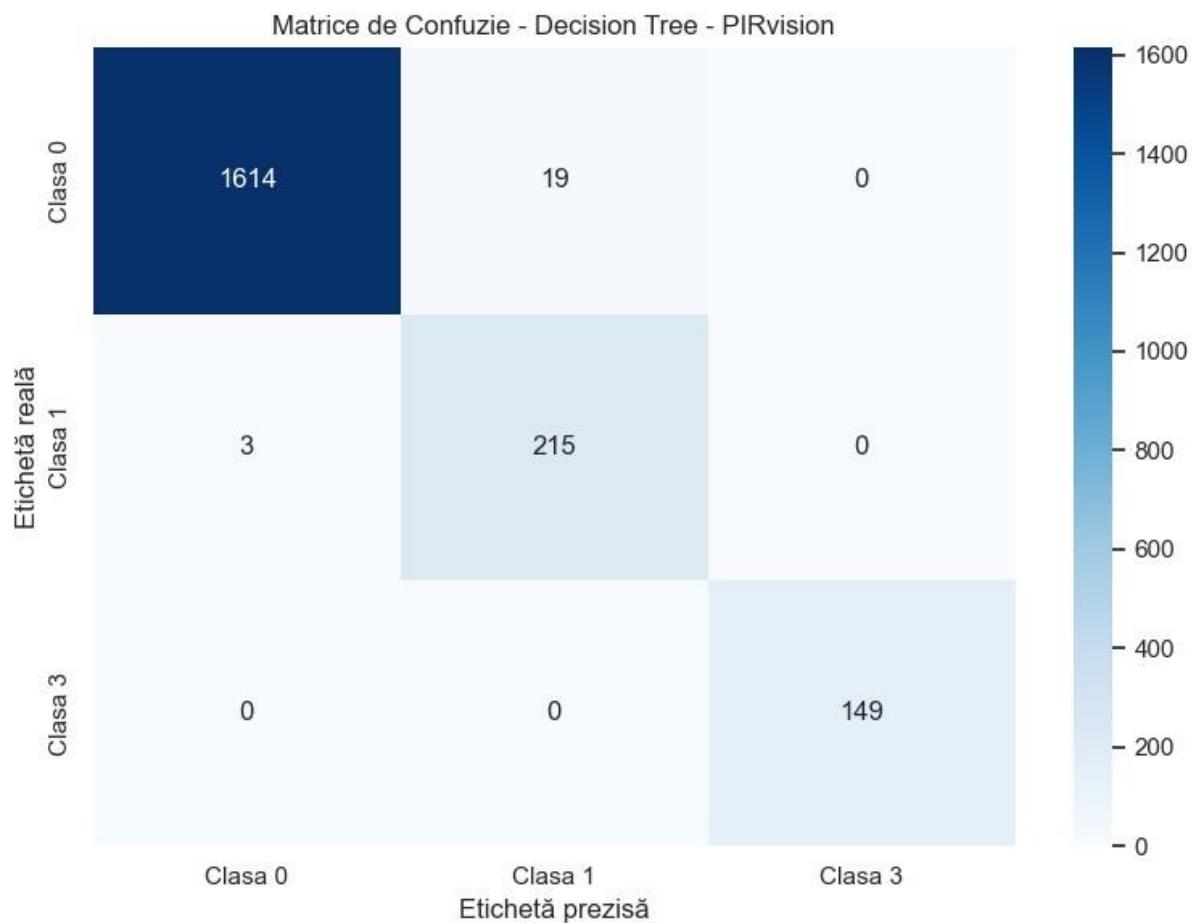
Arbore de Decizie – PIRvision Hiperparametrii alesi:

-criterion="gini" – pentru separarea nodurilor -max_depth=10
– limitam adancimea pentru a evita overfitting

-min_samples_leaf=5 – minim 5 exemple per frunza, pentru regularizare

-class_weight="balanced" – ajusteaza automata pentru clase dezechilibrate

-random_state=42 – pentru reproducibilitate



==== Evaluare Decision Tree - PIRvision ===

Acuratețe: 0.9890

	precision	recall	f1-score	support
Clasa 0	1.00	0.99	0.99	1633
Clasa 1	0.92	0.99	0.95	218
Clasa 3	1.00	1.00	1.00	149
accuracy			0.99	2000
macro avg	0.97	0.99	0.98	2000
weighted avg	0.99	0.99	0.99	2000

Am obtinut o acuratete de 98.9%

Modelul se descurca excellent in identificarea claselor, inclusive cele minoritate.

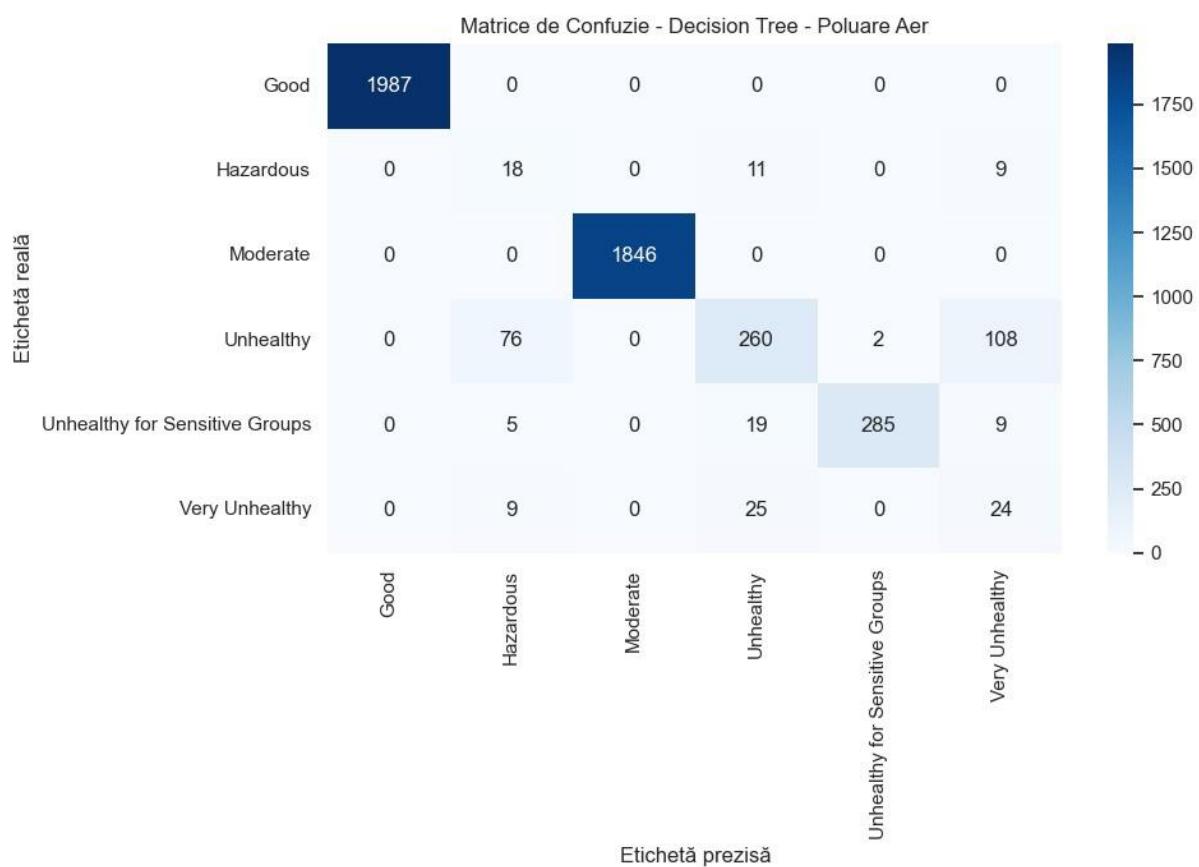
Confuziile apar rareori intre clasele 0 si 1.

Parametrul `class_weight="balanced"` a fost efficient in combaterea dezechilibrului dintre clase (clasa 0 avea de 8 ori mai multe exemple decat clasa 3)

`Max_depth=10` a prevenit overfitting

Arbore de Decizie – Air Pollution Hiperparametrii alesi:

- criterion="gini" – pentru separarea nodurilor -max_depth=10
- limitam adancimea pentru a evita overfitting
- min_samples_leaf=5 – minim 5 exemple per frunza, pentru regularizare
- class_weight="balanced" – ajusteaza automata pentru clase dezechilibrate
- random_state=42 – pentru reproducibilitate



```
== Evaluare Decision Tree - Poluare Aer ==
```

```
Acuratete: 0.9418
```

	precision	recall	f1-score	support
Good	1.00	1.00	1.00	1987
Hazardous	0.17	0.47	0.25	38
Moderate	1.00	1.00	1.00	1846
Unhealthy	0.83	0.58	0.68	446
Unhealthy for Sensitive Groups	0.99	0.90	0.94	318
Very Unhealthy	0.16	0.41	0.23	58
accuracy			0.94	4693
macro avg	0.69	0.73	0.68	4693
weighted avg	0.97	0.94	0.95	4693

Am obtinut o acuratete de 94.18%

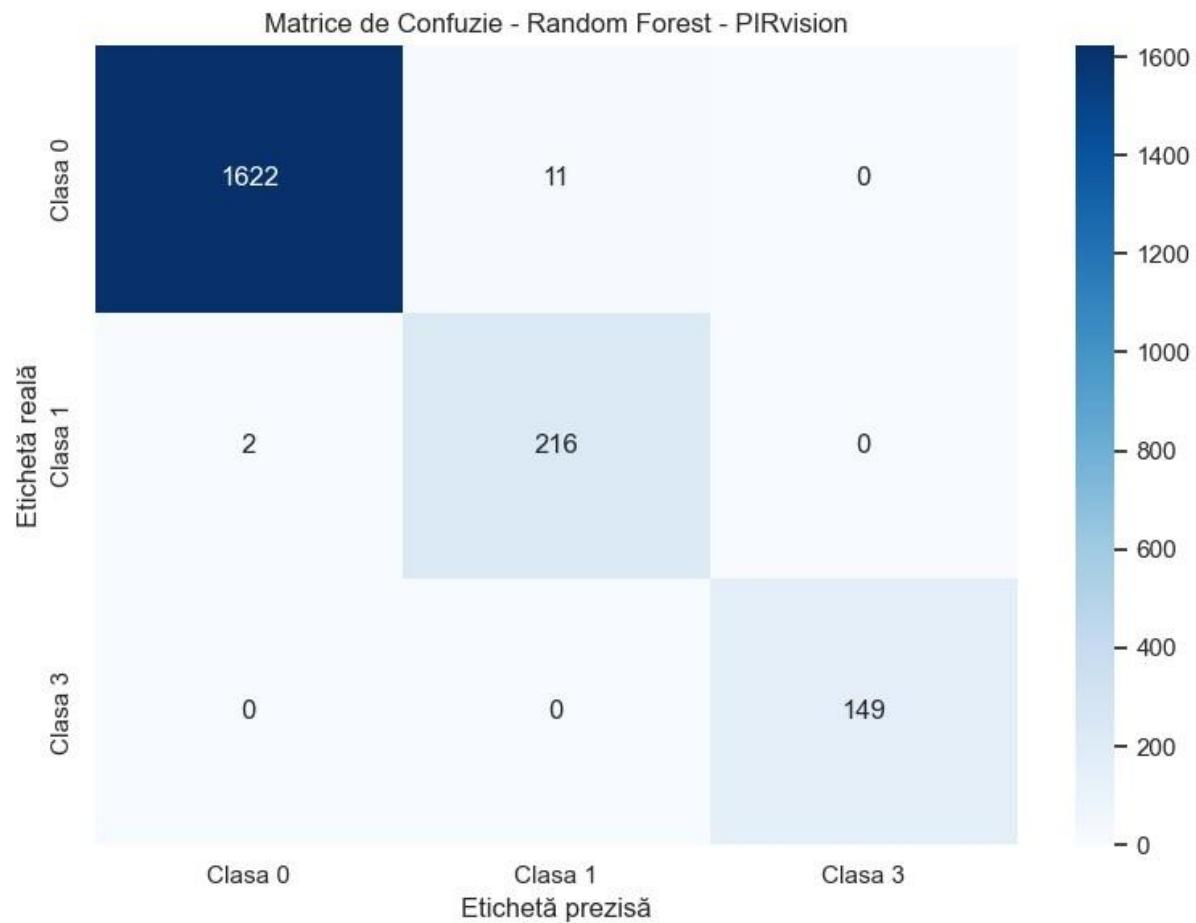
Clasele “Good” si “Moderate” sunt foarte aproape perfect clasificate, avand un volum mare de date si valori numerice bine separate.

Clasele “Hazardous” si “Very Unhealthy” sunt greu de separate din cauza numarului redus de exemple si suprapunerii cu alte clase.

Parametrul `class_weight="balanced"` a imbunatatit vizibil scorurile pentru clasele mici

Păduri Aleatoare – PIRvision

- n_estimators=100 – modelul este compus din 100 arbori
- max_depth=12 – limitam adancimea fiecarui arbore pentru a evita overfitting
- min_samples_leaf=5 – minim 5 exemple per frunza, pentru regularizare
- max_features="sqrt" – selectare randomizata a atributelor
- class_weight="balanced" – ajusteaza automata pentru clase dezechilibrate
- random_state=42 – pentru reproducibilitate



```
==== Evaluare Random Forest - PIRvision ===
```

```
Acuratețe: 0.9935
```

	precision	recall	f1-score	support
Clasa 0	1.00	0.99	1.00	1633
Clasa 1	0.95	0.99	0.97	218
Clasa 3	1.00	1.00	1.00	149
accuracy			0.99	2000
macro avg	0.98	0.99	0.99	2000
weighted avg	0.99	0.99	0.99	2000

Am obtinut o acuratete de 99.35%

Modelul Random Forest a oferit performante mai bune decat arborele de decizie

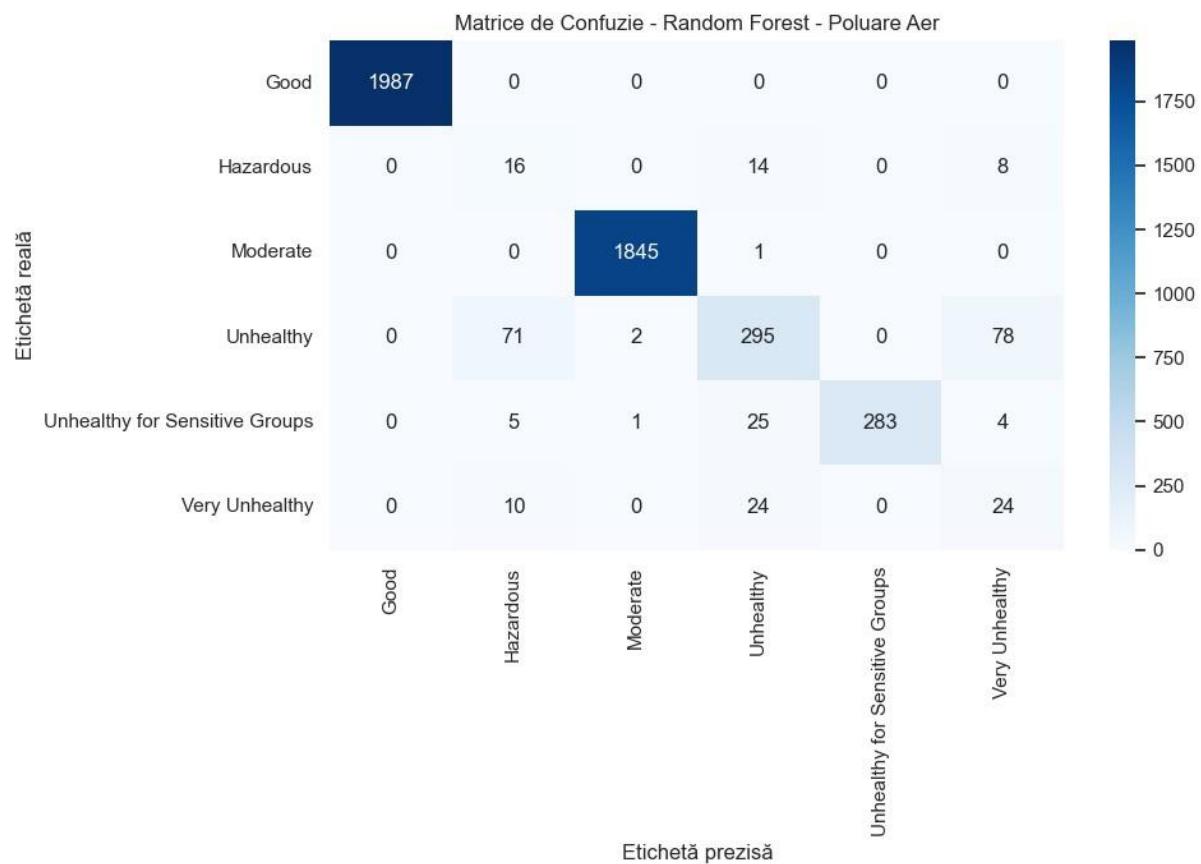
Clasa 3 a fost clasificata perfect

Clasa 1 cu scor F1 de 0.97

Class_weight="balanced" a contribuit la cresterea scorului pentru clasele minoritare

Paduri aleatoare – Air Pollution

- n_estimators=100 – modelul este compus din 100 arbori
- max_depth=14 – limitam adancimea fiecarui arbore pentru a evita overfitting
- min_samples_leaf=5 – minim 5 exemple per frunza, pentru regularizare
- max_features="sqrt" – selectare randomizata a atributelor
- class_weight="balanced" – ajusteaza automata pentru clase dezechilibrate
- random_state=42 – pentru reproducibilitate



==== Evaluare Random Forest - Poluare Aer ===

Acuratețe: 0.9482

	precision	recall	f1-score	support
Good	1.00	1.00	1.00	1987
Hazardous	0.16	0.42	0.23	38
Moderate	1.00	1.00	1.00	1846
Unhealthy	0.82	0.66	0.73	446
Unhealthy for Sensitive Groups	1.00	0.89	0.94	318
Very Unhealthy	0.21	0.41	0.28	58
accuracy			0.95	4693
macro avg	0.70	0.73	0.70	4693
weighted avg	0.97	0.95	0.96	4693

Am obtinut o acuratete de 94.82%

Clasele dominante(Good, Moderate) sunt clasificate excellent(F1=1.00)

Clasele rare precum “Hazardous” si “Very Unhealthy” raman dificil de distins

Fata de arborele de decizie, scorurile pe clasele medii s-au imbunatatit.

Random Forest ofera o generalizare mai buna datorita agregarii multiplelor modele slab corelate.

Regresie Logica - PIRvision

Tipul de codare folosit:

Variabila tinta Class (numerica, dar tratata drept categorie) a fost transformata cu LabelEncoder.

Atributele de intrare (predictori) sunt deja numerice, deci nu a fost necesara codificare suplimentara (ex. One-Hot Encoding).

Optimizator (Gradient Descent):

A fost folosit lbgfs, un optimizator de tip quasi-Newton, recomandat pentru regresie logistica multclasa.

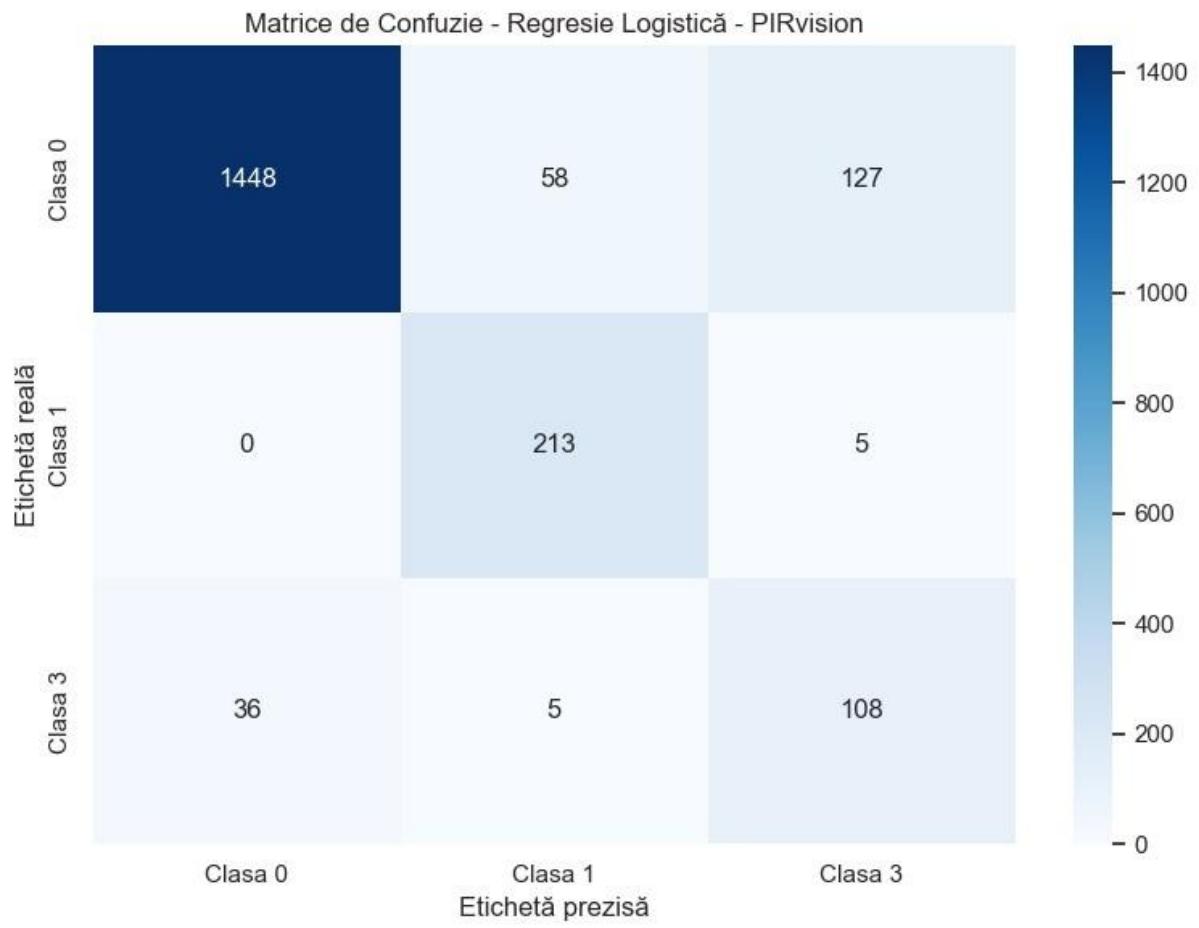
Parametrul max_iter=1000 a fost setat pentru a asigura convergenta in cazul unui set de date cu multe variabile.

Regularizare:

S-a folosit regularizarea L2 (implicita), care penalizeaza coeficientii mari pentru a reduce overfitting-ul.

Nu s-a setat explicit un coeficient C, deci a fost folosita valoarea implicita C=1.0, adica regularizare moderata.

class_weight="balanced" a fost utilizat pentru a corecta dezechilibrul intre clase.



==== Evaluare Regresie Logistică - PIRvision ===

Acuratețe: 0.8845

	precision	recall	f1-score	support
Clasa 0	0.98	0.89	0.93	1633
Clasa 1	0.77	0.98	0.86	218
clasa 3	0.45	0.72	0.56	149
accuracy			0.88	2000
macro avg	0.73	0.86	0.78	2000
weighted avg	0.91	0.88	0.89	2000

Am obtinut o acuratete de 88.45% Clasa majoritara(0) are o precizie excelenta, dar recall-ul scade la 0.89(unele exemple fiind confundate cu Clasa 3) Clasa 1 este foarte bine identificata(recall = 0.98)

Clasa 3 este slab recunoscută (precision = 0.45), ceea ce reflectă dificultatea regresiei logistice în a invata frontier clare pentru clase mici, mai ales în contexte nelineare

Regresie Logistica – Poluare Aer Tipul

de codare folosit:

Variabila tinta Overall AQI Level, fiind de tip categoric, a fost codificata numeric folosind LabelEncoder.

Atributele de intrare folosite in model au fost exclusiv numerice (e.g. CO AQI Value, Ozone AQI Value, NO2 AQI Value, etc.), deci nu a fost necesara codificarea suplimentara prin OneHotEncoder.

Optimizator (Gradient Descent):

Modelul a fost antrenat folosind algoritmul lbgfs, un optimizator de tip quasi-Newton, recomandat pentru regresie logistica multclasa.

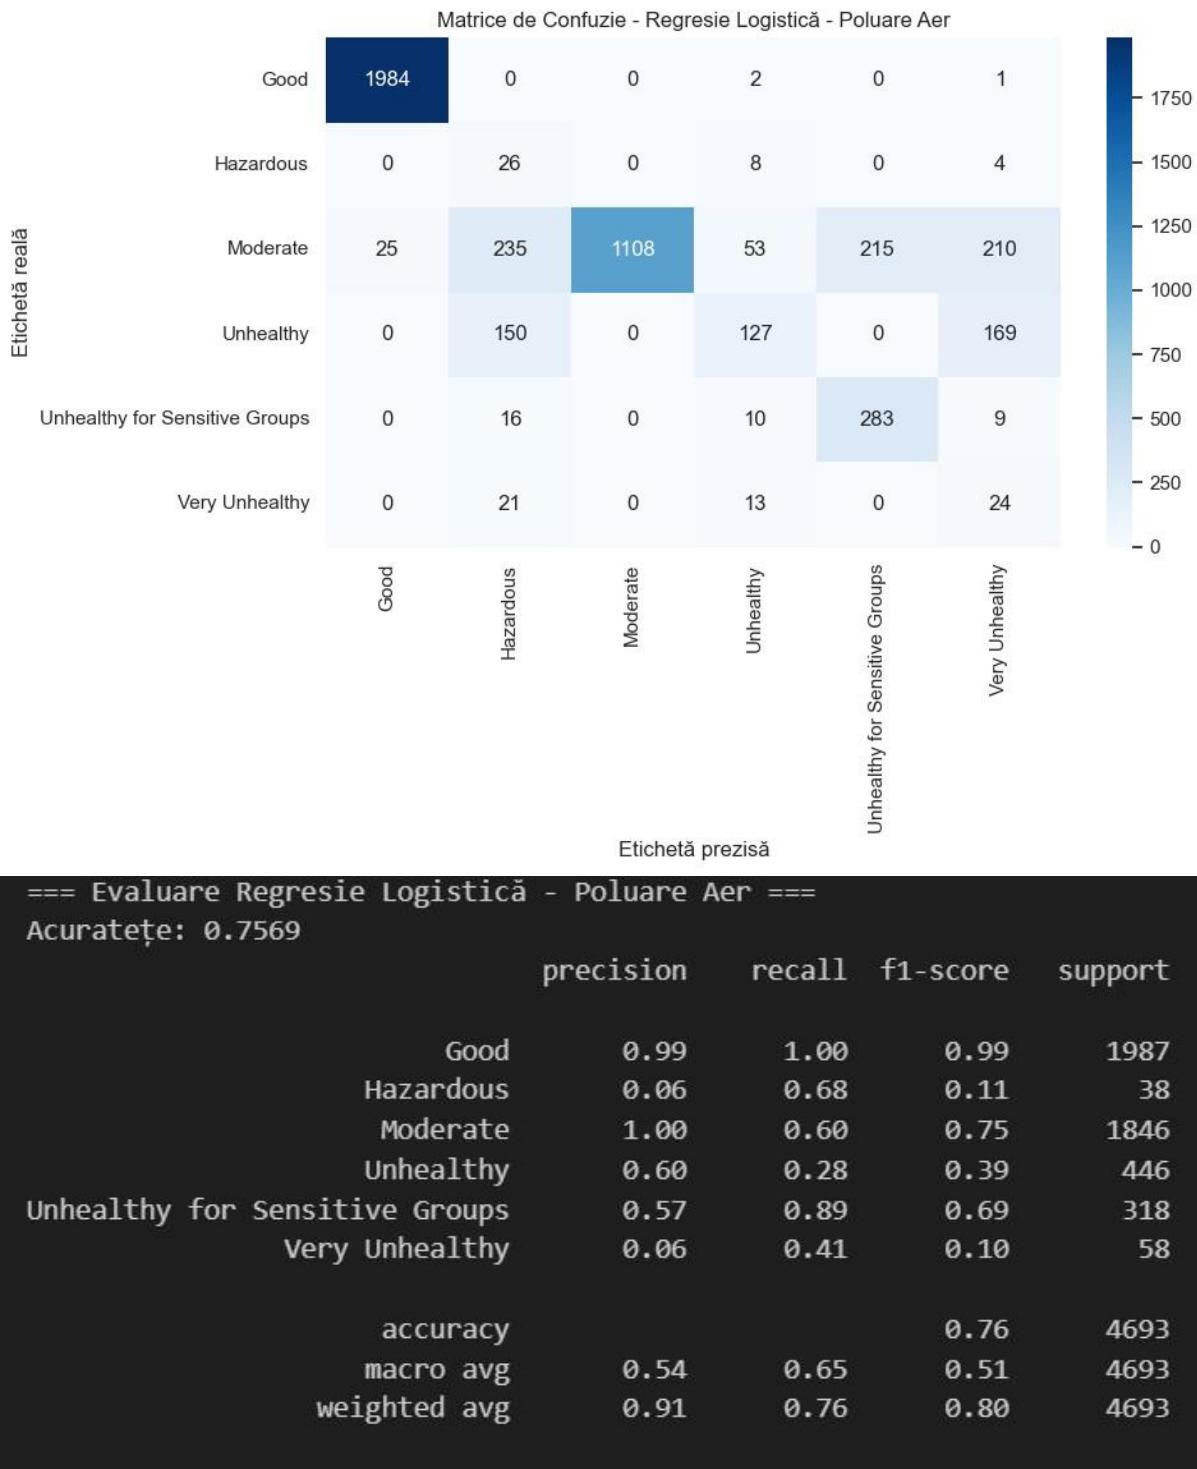
S-a setat max_iter=1000 pentru a permite convergenta in cazul unui volum mare de date si multiple clase tinta.

Regularizare:

S-a utilizat regularizarea implicita L2, care penalizeaza coeficientii mari si reduce overfitting-ul.

Parametrul C a fost lasat la valoarea implicita (C=1.0), echivalent cu regularizare moderata.

Pentru a gestiona dezechilibrul intre clase, a fost setat class_weight="balanced".

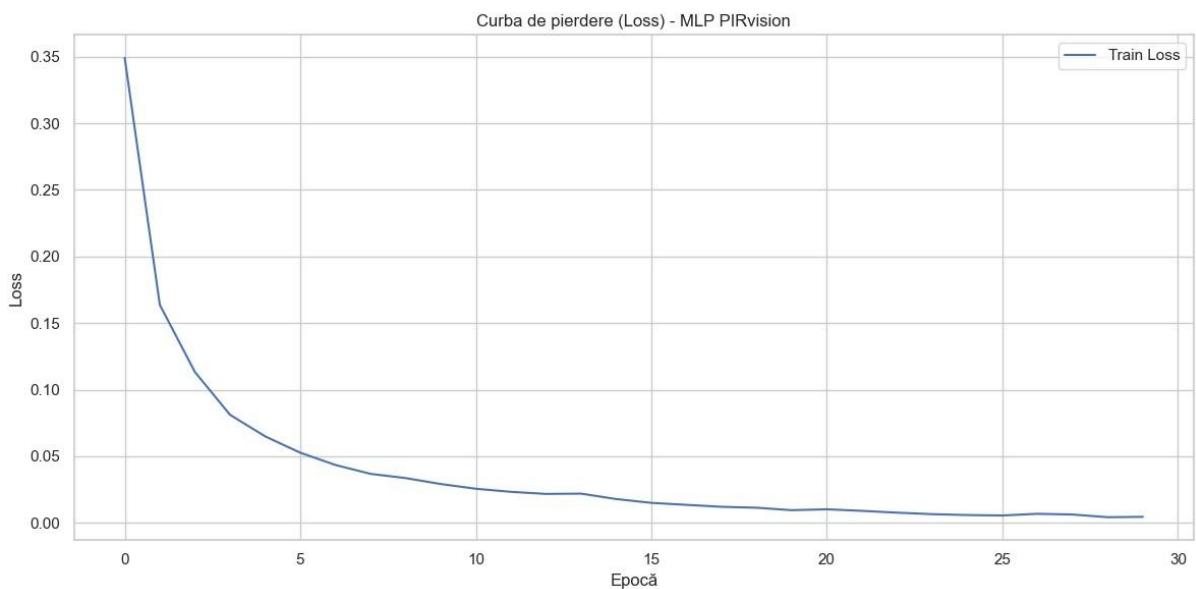


Am obtinut o acuratete de 75.69%

Modelul reuseste sa clasifice corect clasele dominante precum "Good"(precizie si recall ~1.00), dar performanta este scazuta pentru clasele rare precum "Hazardous" sau "Very Unhealthy", cu scoruri f1-score de 0.11 si 0.10

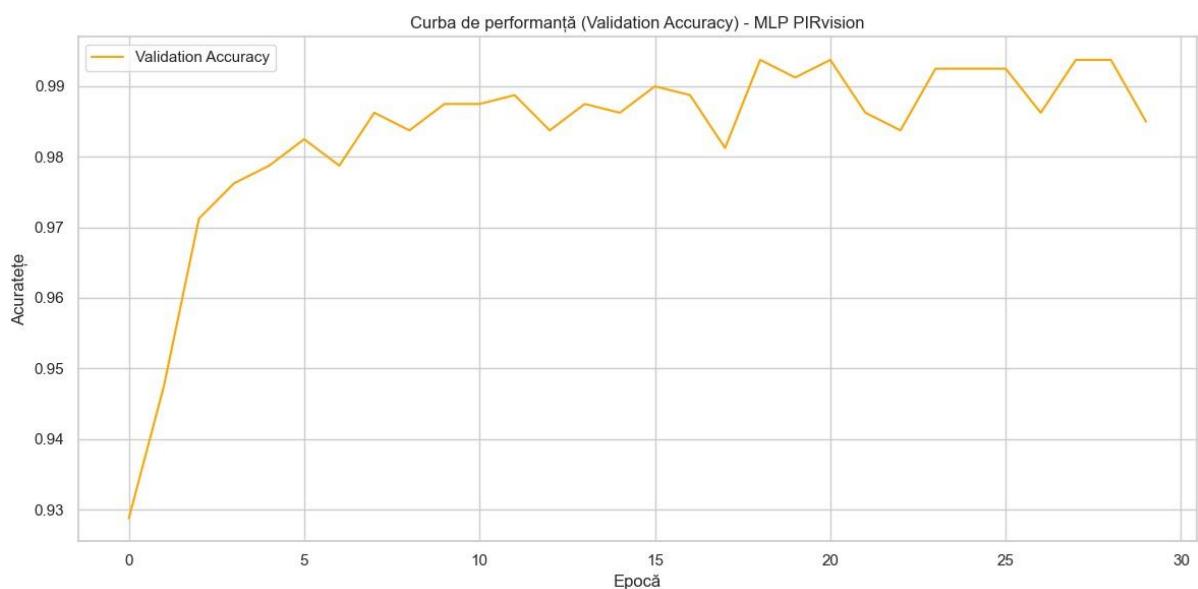
Rezultatele reflecta un dezechilibru al claselor si o dificultate ridicata in generalizarea pe clasele minoritare, in special din cauza suprapunerii valorilor atributelor numerice.

MLP – PIRvision



Curba de pierdere (Loss):

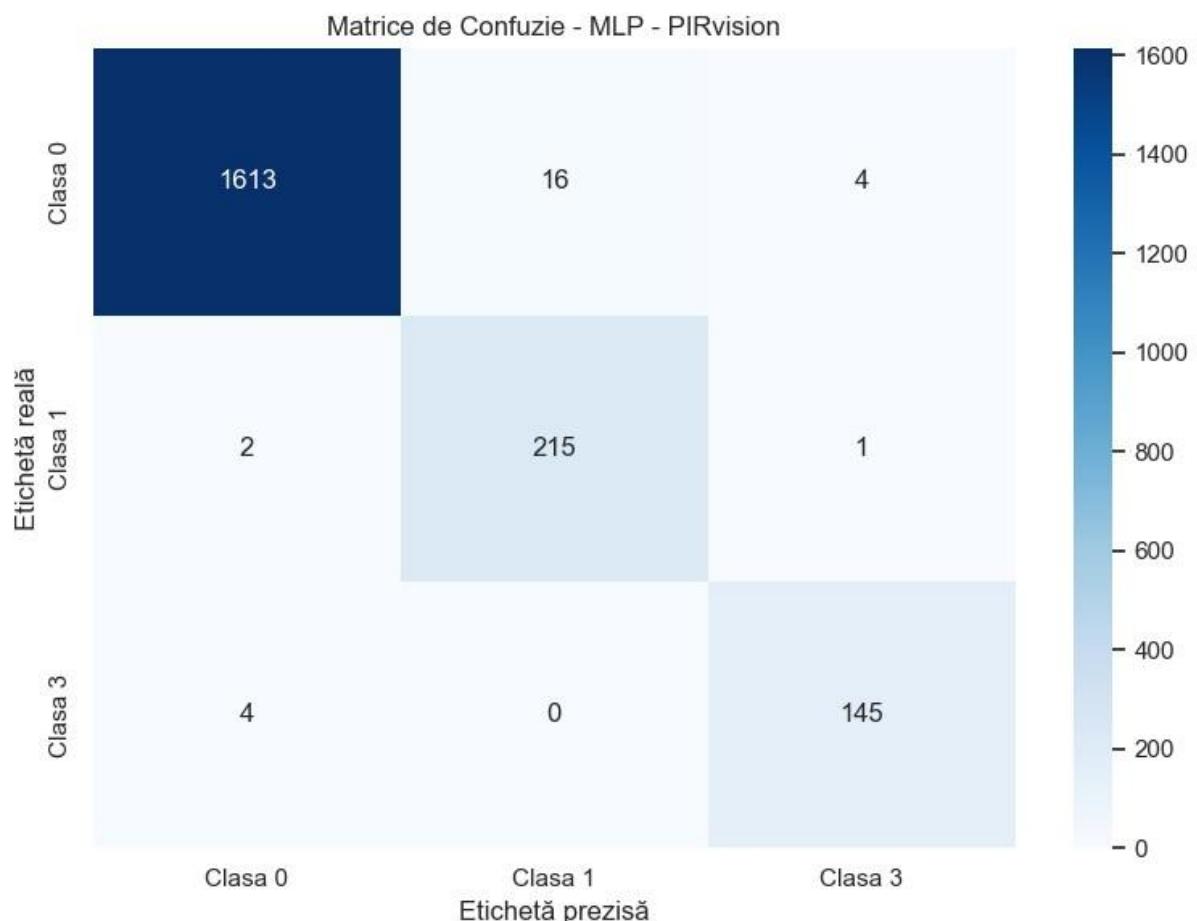
Modelul a invatat eficient din datele de antrenament. Valoarea functiei de pierdere scade constant in primele epoci si se stabilizeaza in jurul unei valori foarte mici dupa aproximativ 20 de epoci. Aceasta evolutie sugereaza ca modelul converge corect, fara fluctuatii majore sau semne de suprainvatare.



Curba de acuratete (Validation Accuracy):

Acuratatea pe setul de validare creste rapid in primele epoci

si se mentine la un nivel ridicat (intre 0.98 si 0.993). Oscilatii minore sunt normale si nu indica overfitting. Nu exista o scadere semnificativa care sa sugereze pierderea capacitatii de generalizare.



==== Evaluare MLP - PIRvision ===

Acuratețe: 0.9865

	precision	recall	f1-score	support
Clasa 0	1.00	0.99	0.99	1633
Clasa 1	0.93	0.99	0.96	218
Clasa 3	0.97	0.97	0.97	149
accuracy			0.99	2000
macro avg	0.96	0.98	0.97	2000
weighted avg	0.99	0.99	0.99	2000

Reteaua neuronală utilizată are o structură compusă din:

- 2 straturi ascunse cu:
 - Primul strat: 64 neuroni
 - Al doilea strat: 32 neuroni
- Functia de activare folosita: ReLU (Rectified Linear Unit)
- Strat de ieșire: clasificare multclasa (activare implicită softmax)

Optimizator și hiperparametri

- Optimizator: Adam (adaptive gradient-based optimizer)
- Learning rate initial: 0.001
- Numar maxim de epoci (max_iter): 300
- Batch size: 64
- Early stopping: activat (pentru a preveni overfitting-ul)
- Random state: 42

Regularizare

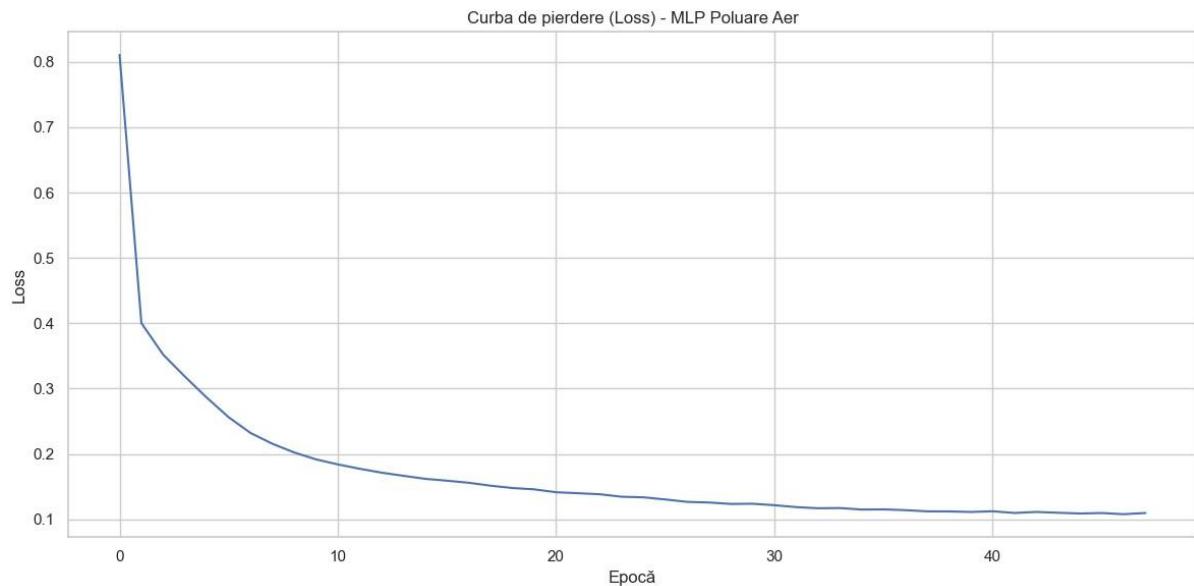
- A fost folosita regularizare L2 cu coeficient alpha = 0.001 .
Early stopping monitorizează performanța pe un set de validare intern și oprește antrenarea cand modelul nu se mai îmbunătățește

Rezultate obținute

- Acuratete totală: 0.9865

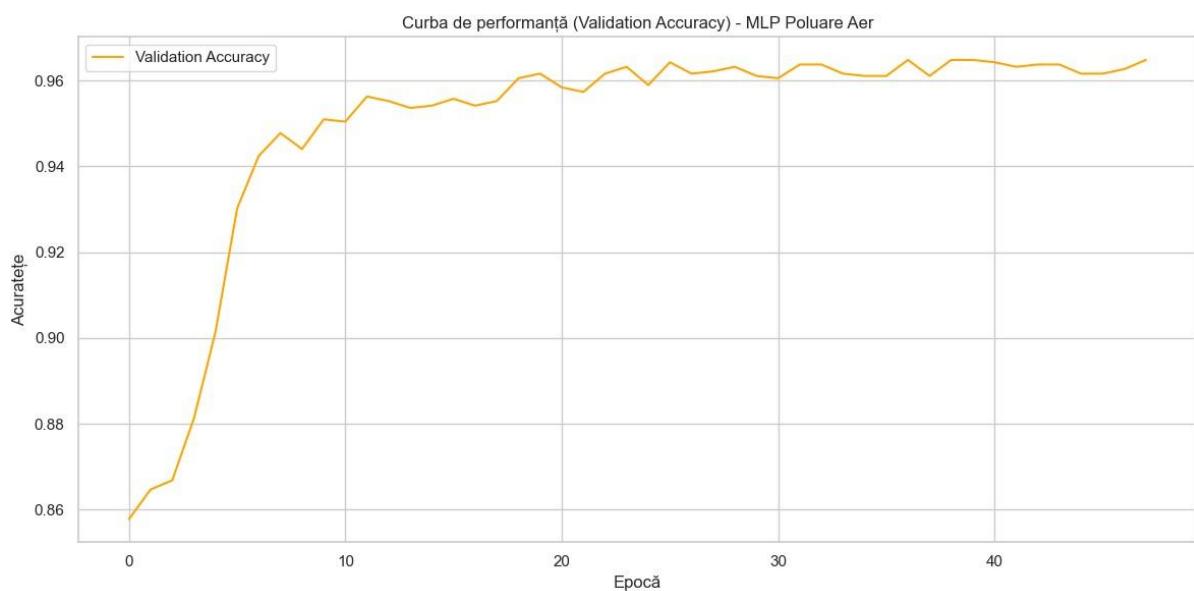
- Matricea de confuzie a aratat ca modelul clasifica corect majoritatea observatiilor pentru toate cele 3 clase (0, 1, 3)
- Curba de pierdere (loss) arata o scadere constanta a erorii in timpul antrenarii, fara semne evidente de overfitting
- Graficul curbei de pierdere este inclus si arata convergenta rapida in aproximativ 30 epoci

MLP - Poluare Aer



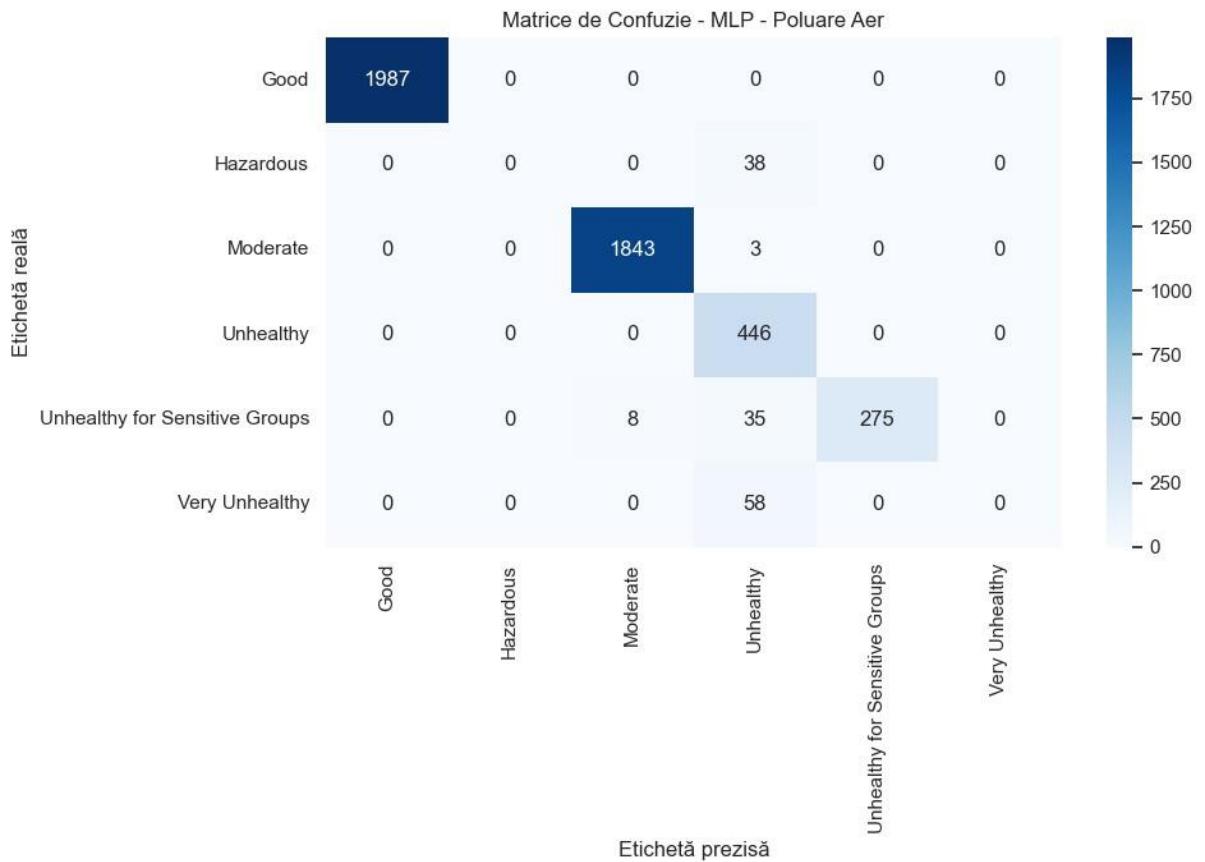
1. Curba de pierdere (Loss)

Graficul arata o scadere constanta a erorii (loss-ului) pe parcursul epocilor, ceea ce indica faptul ca modelul invata in mod eficient. Nu exista fluctuatii sau stagnari semnificative, iar curba devine plata spre final, semn ca modelul se apropie de o convergenta stabila. Acest comportament sugereaza ca modelul nu sufera de overfitting si ca antrenarea s-a realizat in conditii controlate.



2. Curba de performanta (Validation Accuracy)

Aceasta curba urca rapid in primele epoci, atingand o acuratete de validare ridicata (~96%) si ramanand constanta ulterior. Acest lucru confirma ca modelul generalizeaza bine si ca nu exista semne evidente de overfitting (nu scade acuratetea de validare in timp). Micile oscilatii sunt normale si pot fi cauzate de variatia setului de validare.



== Evaluare MLP - Poluare Aer ==

Acuratețe: 0.9697

	precision	recall	f1-score	support
Good	1.00	1.00	1.00	1987
Hazardous	0.00	0.00	0.00	38
Moderate	1.00	1.00	1.00	1846
Unhealthy	0.77	1.00	0.87	446
Unhealthy for Sensitive Groups	1.00	0.86	0.93	318
Very Unhealthy	0.00	0.00	0.00	58
accuracy			0.97	4693
macro avg	0.63	0.64	0.63	4693
weighted avg	0.96	0.97	0.96	4693

Arhitectura rețelei:

- Număr straturi ascunse: 2

- Dimensiunea straturilor: primul strat cu 64 de neuroni, al doilea cu 32 de neuroni
- Funcția de activare: ReLU (activation='relu') Optimizator:
- Tip optimizator: Adam (solver='adam')
- Learning rate inițial: 0.001 (learning_rate_init=0.001)
- Număr maxim de epoci: 300 (max_iter=300)
- Dimensiune batch: 64 (batch_size=64) Metode de regularizare:
- Regularizare L2 cu coeficient alpha=0.001 (implicit în scikit-learn pentru MLPClassifier)
- Activarea opțiunii early_stopping=True pentru a preveni overfitting-ul prin oprirea antrenării atunci când performanța pe setul de validare nu mai crește

Tabel comparativ al performanței algoritmilor de clasificare pe seturile de date PIRvision și Poluare Aer

	Model	Accuracy	Precizie clasa 0	Recall clasa 0	F1 clasa 0	Precizie clasa 1	Recall clasa 1	F1 clasa 1	Precizie clasa 2	Recall clasa 2	F1 clasa 2	Precizie clasa 3	Recall clasa 3	F1 clasa 3	Precizie clasa 4	Recall clasa 4	F1 clasa 4
0	Decision Tree - PIRvision	0.9890	0.9981	0.9884	0.9932	0.9188	0.9862	0.9513	**1.0000**	**1.0000**	**1.0000**	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
1	Random Forest - PIRvision	**0.9935**	0.9988	0.9933	0.9960	**0.9515**	**0.9908**	**0.9708**	**1.0000**	**1.0000**	**1.0000**	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
2	Logistic Regression - PIRvision	0.8845	0.9757	0.8867	0.9291	0.7717	0.9771	0.8623	0.4500	0.7248	0.5553	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
3	MLP - PIRvision	0.9865	0.9963	0.9878	0.9920	0.9307	0.9862	0.9577	0.9667	0.9732	0.9699	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
4	Decision Tree - Poluare Aer	0.9416	**1.0000**	**1.0000**	**1.0000**	0.1442	0.3947	0.2113	**1.0000**	**1.0000**	**1.0000**	**0.8179**	0.5942	0.6883	**1.0000**	**0.8899**	**0.9418**
5	Random Forest - Poluare Aer	0.9482	**1.0000**	**1.0000**	**1.0000**	0.1485	0.3947	0.2158	0.9984	**1.0000**	0.9992	0.8154	0.6637	0.7318	**1.0000**	**0.8899**	**0.9418**
6	Logistic Regression - Poluare Aer	0.7569	0.9876	0.9985	0.9930	0.0580	0.6842	0.1070	**1.0000**	0.6002	0.7502	0.5962	0.2848	0.3854	0.5683	**0.8899**	0.6936
7	MLP - Poluare Aer	0.9697	**1.0000**	**1.0000**	**1.0000**	0.0000	0.0000	0.0000	0.9957	0.9984	0.9970	0.7690	**1.0000**	**0.8694**	**1.0000**	0.8648	0.9275

1. Setul de date PIRvision

Pe acest set, toți cei patru algoritmi (Decision Tree, Random Forest, Logistic Regression, MLP) au obținut scoruri ridicate, dar Random Forest este modelul cel mai performant:

-A obținut cea mai mare acuratete (0.9935) și cele mai mari scoruri F1, precizie și recall pentru clasele predominante (clasa 0, clasa 1, clasa 2).

-Explicatie: Random Forest combina mai multi arbori de decizie și reduce suprainvatarea. Acest lucru îi permite să generalizeze mai bine pe un set ca PIRvision, care pare să aibă structuri de date bine definite între clase.

-În plus, clasele 3, 4, 5 au scoruri 0 pentru toți algoritmii (ceea ce sugerează că ele sunt fie foarte rare, fie absente în setul de test). Acest lucru explica de ce și modelele foarte bune nu le pot prezice corect.

2. Setul de date Poluare Aer

Aici, MLP este modelul cu cea mai mare acuratete (0.9697), urmat de Random Forest (0.9482).

-Random Forest are o performanta buna si echilibrata, dar MLP reuseste sa atinga scoruri perfecte (1.0) pentru clasele 0 si 3 si scoruri ridicate pentru clasele 2 si 4.

-MLP functioneaza bine pentru ca poate modela relatii complexe nelineare in datele de mediu (care includ multi factori corelati – temperatura, poluanti etc.).

-Clasele 1 si 5 sunt problematice pentru toti algoritmii (mai ales Logistic Regression si MLP, care au scoruri foarte slabe sau 0). Acest lucru sugereaza ca aceste clase sunt dezechilibrate sau greu de separat, posibil din cauza suprapunerii in spatiul de trasaturi (features).

Concluzie generala

-Random Forest este cel mai constant algoritm performant pe ambele seturi de date – ofera o combinatie buna intre acuratete si robustete in fata dezechilibrelor de clasa.

-MLP reuseste performante excelente pe setul "Poluare Aer", datorita capacitati sale de a invata modele complexe. Insa are dificultati cand anumite clase lipsesc sau sunt foarte rare.

-Logistic Regression este cel mai slab model pe ambele seturi, in special pe cel de poluare, deoarece relatiiile dintre variabile sunt probabil nelineare si nu pot fi modelate bine de un model liniar.